

分类号 TP391
收藏编号
学校代码 10386



学号 221027011
编号

福州大学

工程硕士专业学位研究生学位论文 (毕业) 论文
(应用研究)

基于化学反应优化的聚类算法研究

工 程 领 域: 计算机技术

研 究 方 向: 云计算与大数据技术

研 究 生 姓 名: 陈锦聪

指 导 教 师、职 称: 何振峰 副教授

协 助 导 师、职 称:

所 在 学 院: 计算机与大数据学院

答 辩 委 员 会 主 席: 邵明仕

二〇二五年六月

一 遵守学术行为规范承诺

本人已熟知并愿意自觉遵守《福州大学研究生和导师学术行为规范实施办法》和《福州大学关于加强研究生毕业与学位论文质量管理的规定》的所有内容，承诺所提交的毕业和学位论文是终稿，不存在学术造假或学术不端行为，且论文的纸质版与电子版内容完全一致。

二 独创性声明

本人声明所呈交的学位论文是本人在导师指导下独立进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人或其他集体已经发表或撰写过的研究成果，也不包含为获得福州大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。本人完全意识到本声明的法律结果由本人承担。

三 学位论文版权使用授权书

按照国家有关保密规定，本学位论文不涉密。本学位论文作者完全了解国家有关保留、使用学位论文的法律、法规和学校有关规定，并同意以下事项：

1、学校有权保留并向国家有关部门或机构送交本学位论文的复印件和相关电子储存介质，允许论文被查阅和借阅；

2、学校可以将本学位论文的全部或部分内容编入有关数据库进行信息技术服务，可以采用影印、缩印或扫描等复制手段保存、汇编本学位论文，并用于学术活动。

本学位论文属于（必须在以下相应方框内打“√”，否则一律按“公开论文”处理）：

☐ 暂不公开论文：由于本学位论文的部分研究成果处于申报知识产权保护期间，因此本学位论文申请暂不对外公开，将在二年后对外公开并按本授权书处理。

☒ 公开论文：本学位论文可对外公开，并按本授权书处理。

研究生本人签名：陈锦泉

签字日期：2025年4月5日

研究生导师签名：何如峰

签字日期：2025年4月5日

基于化学反应优化的聚类算法研究

中文摘要

化学反应优化算法 (Chemical Reaction Optimization, CRO) 因其简单、高效而被广泛应用于解决各类优化问题, 其中包括通过优化簇中心来实现聚类。然而, 该算法收敛精度低较易陷入局部最优。另一方面, 传统基于簇中心优化的聚类方法在处理非凸数据集时能力有限, 且往往需要预先指定簇数, 限制了其实用性。针对以上问题, 本研究提出了一系列改进方案, 具体内容如下:

(1) 基于改进实数编码化学反应优化的聚类算法。随着数据规模、维度的增加, 化学反应优化算法在优化簇中心过程中有可能收敛到局部最优解, 且收敛速度较慢、收敛精度低。为此, 本文从三个方面改进该算法。首先指出原初始化策略在高维空间中难以维持均匀分布, 因此引入了 Sine 混沌映射来初始化分子集; 接着指出原双分子无效碰撞与单分子撞墙反应在搜索机制上缺乏差异性, 限制了搜索的灵活性, 且父代之间缺少信息交流, 因此提出基于算术交叉的双分子无效碰撞反应; 最后指出合成反应可能选取两个低质量分子参与反应, 降低搜索效率, 为此在对黄金正弦算法进行改进后, 引入作为合成算子。最后将改进算法分别用来解决连续优化和聚类问题。实验结果表明, 所提算法在连续优化和聚类任务中均表现出显著优势。

(2) 自适应化学反应优化聚类算法。由于传统聚类算法在非凸数据集上表现不佳且需要预先指定簇的数量, 本文尝试借鉴化学反应机制来实现簇的演化过程。算法首先基于互近邻关系构建初始分子集, 随后通过合成反应与分解反应的交替执行实现簇结构的自适应优化。在分解阶段, 将分子视为一个图结构, 引入谱分解理论评估分子的势能, 并将分子分解为更小的子结构; 在合成阶段, 通过跨分子相互作用力量化动能, 引入吉布斯自由能判据表征热力学可行性, 同时考虑中心原子之间电子云重叠程度, 以综合判断合成反应的可行性。实验结果表明, 所提算法在处理非凸数据集时表现出色。

关键词: 聚类分析; 化学反应优化算法; 元启发式算法; 自适应聚类

The Research on Clustering Algorithm Based on Chemical Reaction Optimization

Abstract

The Chemical Reaction Optimization (CRO) algorithm, valued for its simplicity and efficiency, is widely applied to address various optimization challenges, including clustering through the optimization of cluster centers. However, it suffers from low convergence accuracy and a tendency to become trapped in local optima. Meanwhile, traditional clustering methods reliant on cluster center optimization exhibit limited effectiveness when processing non-convex datasets and typically require the number of clusters to be pre-specified, thus constraining their practical utility. To tackle these shortcomings, this study introduces a series of enhancements, outlined as follows:

(1) A Clustering Algorithm Based on Improved Real-Coded Chemical Reaction Optimization (IRCCRO). As data scale and dimensionality grow, the CRO algorithm risks converging to local optima during cluster center optimization, with slow convergence rates and reduced accuracy. To address this, we enhance the algorithm in three key ways. First, we identify that the original initialization strategy struggles to maintain uniform distribution in high-dimensional spaces and introduce the Sine chaotic map to initialize the molecule set. Second, we note that the original mechanisms of inter-molecular ineffective collision and on-wall ineffective collision lack diversity in their search strategies and fail to facilitate information exchange between parent molecules, limiting search flexibility. We thus propose an inter-molecular ineffective collision reaction based on arithmetic crossover. Third, we observe that the synthesis reaction may involve two low-quality molecules, diminishing search efficiency. To remedy this, we enhance the Golden Sine algorithm and incorporate it as the synthesis operator. The improved algorithm is applied to both continuous optimization and clustering tasks, with experimental results demonstrating significant advantages in both domains.

(2) An Adaptive Chemical Reaction Optimization Clustering Algorithm. Traditional clustering algorithms often underperform on non-convex datasets and require the number of clusters to be predefined. To overcome this, we innovatively leverage the chemical reaction mechanism to simulate cluster evolution. The algorithm begins by constructing an initial molecule set based on mutual nearest neighbor relationships, followed by adaptive optimization of the cluster structure through alternating synthesis and decomposition

reactions. In the decomposition phase, molecules are treated as graph structures, and spectral decomposition theory is introduced to evaluate molecular potential energy, decomposing molecules into smaller substructures. In the synthesis phase, kinetic energy is quantified through cross-molecular interactions, and the Gibbs free energy criterion is introduced to evaluate thermodynamic feasibility, while accounting for electron cloud overlap between central atoms to comprehensively assess the feasibility of synthesis reactions. Experimental results confirm the algorithm's superior performance in handling non-convex datasets.

Key words:Clustering Analysis;Chemical Reaction Optimization Algorithm;Meta-heuristic Algorithm;Adaptive Clustering

目录

中文摘要	I
Abstract	II
第一章 引言	1
1.1 选题背景与意义	1
1.2 国内外研究现状	2
1.2.1 实数编码化学反应优化算法研究现状	2
1.2.2 化学反应优化聚类算法研究现状	3
1.3 研究内容与安排	3
第二章 相关工作概述	5
2.1 化学反应优化算法	5
2.1.1 算法基本原理	5
2.1.2 四种基本反应操作	6
2.1.3 实数编码化学反应优化算法	9
2.1.4 算法特点	12
2.2 聚类	13
2.2.1 聚类综述	13
2.2.2 聚类有效性指标	14
2.3 化学反应优化聚类	15
2.3.1 直接优化聚类中心	15
2.3.2 混合优化聚类中心	16
2.4 近邻关系	18
2.5 谱分解	19
2.5.1 瑞利商	19
2.5.2 图分割问题	19
2.6 实验环境与数据	20
2.6.1 实验环境	20
2.6.2 实验数据	21
2.7 本章小结	24
第三章 基于改进实数编码化学反应优化的聚类算法	25
3.1 实数编码化学反应优化算法的改进	25
3.1.1 基于 Sine 混沌映射的初始化策略	25
3.1.2 基于算术交叉的双分子无效碰撞反应	27

3.1.3 基于改进黄金正弦算法的合成反应	28
3.1.4 IRCCRO 算法流程	31
3.2 改进实数编码化学反应优化算法在聚类上的应用	32
3.3 实验及分析	34
3.3.1 IRCCRO 求解连续函数的性能	34
3.3.2 IRCCRO 处理聚类问题的性能	37
3.4 本章小结	38
第四章 自适应化学反应优化聚类算法	40
4.1 引言	40
4.2 基于化学反应优化的双阶段自适应聚类算法	41
4.2.1 基于互近邻的初始分子集构建	41
4.2.2 基于谱分解的分解反应	43
4.2.3 合成反应机制	45
4.2.4 自适应化学反应聚类算法	51
4.3 实验及分析	53
4.3.1 实验设计	53
4.3.2 实验结果与分析	53
4.4 本章小结	59
结论	60
参考文献	62
致 谢	67
个人简历	68
在学期间的研究成果及发表的学术论文	69

第一章 引言

1.1 选题背景与意义

近年来，物联网、大数据、移动云计算等技术的进步使得人们可以更方便地获取、存储大量数据。据 IDC 预测，2025 年全球的数据总量将增长至 175ZB^[1]。如何从这些海量的、高维度的、复杂的数据中挖掘出有价值的信息和知识，是数据挖掘领域的主要挑战。

聚类分析^[2]是一种无监督学习方法，它的目的是将数据集中的实例分组为多个簇，使得同一个簇内的实例彼此相似，而不同簇的实例则不相似^[3]。聚类可以发现数据的内在结构和模式，为其他任务提供有价值的先验信息。例如，在筛选潜在药物时^[4]，聚类可以用于将化合物按其化学结构或生物活性进行分类。这有助于更精准地定位具有潜在疗效的化合物，节省研究资源 and 时间。在自然语言处理中，我们可以通过聚类分析对大量的文本进行主题建模^[5]，从而识别文档的主题，为后续的文档搜索和推荐等任务提供便利。

聚类算法^[2]主要可分为划分、层次、密度以及基于网格的方法。根据 No Free Lunch 定理^[6]，不存在一种通用算法能够在所有问题上均达到最优性能，不同的聚类算法在处理不同类型的数据集时往往表现出不同的性能。以经典的 KMeans^[7]算法为例，该算法通过不断更新簇中心并重新分配数据点来最小化簇内平方误差和。尽管该算法逻辑清晰、易于实现，并在多种应用场景中表现出色，但其局限性也较为明显：对初始质心敏感、需要预设簇数，难以有效处理不规则形状簇。DBSCAN^[8]等基于密度的算法虽然在发现任意形状簇方面表现优异，但在处理高维数据时性能下降明显，且对参数设置较为依赖。

综上所述，现有聚类算法各有其优势与局限性，难以完全适应日益复杂的数据分析需求。尤其是在面对高维数据、非凸簇结构等场景时，传统算法的性能往往受到限制。因此，针对不同数据特性和应用场景，改进或探索新的聚类算法，仍然是当前机器学习领域的一个重要研究方向。其中一种思路是基于元启发式算法的聚类算法^[9-11]。

元启发式算法^[12,13]是受自然过程中的某些行为启发而发展出来的算法，其主要特点是能够提供高效的、全局的搜索策略，以快速找到问题的近似最优解。元启发式算法包括了遗传算法^[14]、粒子群优化算法^[15]、蚁群优化算法^[16]、模拟退火算法^[17]等。在解决复杂优化问题时，尤其是在面对解空间规模庞大且结构复杂的情形下，这些算法展现出了显著的性能优势。传统搜索和优化方法往往容易陷入局部最优，而元启发式算法凭借其灵活的搜索策略，有一定概率跳出局部最优区

域，从而更有可能发现全局最优或高质量的近似解。

化学反应优化算法^[18] (Chemical Reaction Optimization, CRO) 是由香港大学的 Albert Y.S. Lam 和 Victor O.K. Li 于 2010 年提出的一种新型元启发式算法，其设计灵感源于分子在化学反应中趋向于能量稳定状态这一自然现象。该算法通过模拟化学反应中的四种基本反应（对墙无效碰撞反应、分子间无效碰撞、分解反应和合成反应），在解空间搜索过程中实现全局探索与局部开发的动态平衡，从而在求解复杂优化问题时展现出显著的优势。本文旨在将 CRO 算法的优势特性与聚类分析的需求相结合，以期更好地解决聚类问题。

1.2 国内外研究现状

1.2.1 实数编码化学反应优化算法研究现状

化学反应优化算法最初是为解决离散优化问题而设计的，为了将其扩展到连续优化问题中，Lam^[19]等人在 2012 年提出了实数编码化学反应优化算法 (Real-Coded Chemical Reaction Optimization, RCCRO)。RCCRO 通过引入实编码机制和基于高斯分布的邻域搜索算子，能够有效地处理连续空间中的优化问题。为了进一步提升 RCCRO 的性能，Yu^[20]等人深入探讨了高斯分布、柯西分布、指数分布和修正的瑞利分布这四种不同的概率分布函数作为扰动函数对算法表现的影响。鉴于 RCCRO^[21]算法涉及较多需要调优的参数，该研究团队继而提出了自适应化学反应优化算法 (Adaptive Chemical Reaction Optimization, ACRO)，该算法不仅将算法中原有的 8 个参数精简为 3 个，还将 1/5 成功准则引入来自适应更新步长。Li^[22]等人提出了正交化学反应优化算法 (OCRO)，通过引入正交实验设计 (OED)，增强了算法的全局搜索能力。此外，化学反应优化算法可以很容易地与其他启发式算法结合，以进一步提高搜索效率和解的质量。Nguyen^[23]将化学反应优化与粒子群优化进行混合 (HP-CRO)，增强了 CRO 的全局搜索能力。Duc 等人^[24]在 HP-CRO 的基础上引入 Mean-Search 算子 (MSO)，弥补了由 PSO 和单一局部搜索策略所带来的探索能力不足的问题。Roy^[25]等人将 DE 的变异和交叉操作嵌入 CRO 的反应机制中，增强算法的局部搜索能力和收敛速度。Li^[26]等人提出了一种名为 EBCRO 的混合优化算法，该算法则是将人工蜂群算法中改进雇佣蜂操作引入化学反应优化算法中，以提高其全局搜索的能力。Ma^[27]等人借鉴 DE/best/1 的思想提出了 MCRO，即利用最优分子信息引导分子更新，使分子朝着最优方向移动，从而加速收敛速度。

1.2.2 化学反应优化聚类算法研究现状

化学反应优化算法已经被一些学者用来解决聚类问题，有如下的几种思路。

(1) 直接使用化学反应优化算法进行聚类：Baral^[28]将每个分子编码为由所有聚类中心构成的向量，再使用化学反应优化算法进行优化。Hudaib^[29]则是采用基于实际数据点的编码方法。Daniel 等人提出 MCRO 算法^[30]，该算法通过转向算子在局部搜索空间中进行精细调整，同时利用突变算子在全局搜索空间中引入多样性。

(2) 先使用化学反应优化算法优化簇中心，然后将优化后的簇心输入传统聚类算法进行迭代，进一步优化聚类结果：Neamah 等人^[31]利用化学反应优化算法来优化初始候选质心，帮助提高 K-Medoids 聚类的效果。Nayak^[32]则是将优化后的簇心输入使用 FCM 进行优化。

(3) 利用传统聚类算法生成初步聚类结果，再将这些结果作为化学反应优化算法的初始分子集合进行优化迭代。例如，Gao^[5]多次运行 KMeans 生成不同的聚类结果，然后将这些结果作为化学反应优化算法的初始分子集合，通过反复迭代不断优化，最终获得更优的聚类方案。

(4) 将传统聚类算法嵌入到化学反应优化算法的框架中，作为反应算子的一部分：如 Panigrahi^[33]等人使用 KMeans 作为对墙无效碰撞反应，增强算法的局部搜索能力。

1.3 研究内容与安排

全文共分为 5 个章节，各章内容安排如下。

第一章：绪论。本章主要介绍了基于化学反应优化算法的聚类算法研究背景与意义，并对实数编码化学反应优化算法和化学反应优化聚类算法研究现状进行了阐述。

第二章：相关工作描述。本章系统地梳理了与本研究密切相关的理论基础，为后续研究工作构建了坚实的理论支撑。首先，详细介绍了化学反应优化算法的基本原理、实数编码化学反应优化算法及其改进，并分析了该算法相较于其它元启发式算法的优势；其次，概述了几种常见的聚类算法，探讨了它们的优缺点，并介绍了用于评估聚类效果的指标；第三部分重点讨论了基于化学反应优化的聚类算法及其局限性；第四部分阐述了邻近关系的概念；第五部分介绍了谱分解技术，包括瑞利商和图的二分割问题；最后，介绍了实验环境与所用数据集。

第三章：基于改进实数编码化学反应优化的聚类算法。为了解决原始初始化策略在高维空间中难以保持均匀分布的问题，本文引入了 Sine 混沌映射来初始

化分子集合。其次，原有的双分子无效碰撞和单分子撞墙反应在搜索机制上缺乏差异性，潜在有价值信息未能及时整合。为此，本文提出了基于算术交叉的双分子无效碰撞反应，以增强搜索的灵活性并促进信息共享。最后，针对合成反应搜索效率低下的问题，本文在改进黄金正弦算法后，将其引入作为合成算子。实验结果表明，改进的算法在优化和聚类中均表现出显著优势。

第四章：自适应化学反应优化聚类算法。针对传统聚类算法在非凸数据集上表现不佳且需要预先指定簇数量的问题，本文提出了一种基于自适应化学反应优化的聚类算法，通过模拟簇的演化过程实现自适应优化。具体内容如下：首先，算法基于互近邻关系构建初始分子集合；随后，通过交替执行合成反应与分解反应，实现簇结构的动态调整。在分解阶段，将分子视为图结构，引入谱分解理论计算势能并将其拆分为更小的子结构；在合成阶段，通过量化跨分子相互作用力计算动能，同时引入吉布斯自由能判据表征热力学可行性，并综合考虑中心原子间电子云的重叠程度，以判断合成反应的可行性。在整个优化过程中，算法根据合成成功率来触发分解反应，从而自适应地调整簇数与结构。实验结果表明，该算法在处理非凸数据集时表现优异。

第二章 相关工作概述

2.1 化学反应优化算法

2.1.1 算法基本原理

化学反应优化算法是一种受化学反应过程启发的元启发式算法。该算法通过模拟化学反应中分子间的相互作用和能量转化的过程,逐步寻找优化问题的最优解。在化学反应优化算法中,每个候选解都被抽象表示为一个分子,每个分子具有两种重要的能量属性:势能(Potential Energy,PE)和动能(Kinetic Energy,KE)。势能即要优化的目标函数值,反映了解的优劣;动能反映了分子在搜索过程中接受较差解的能力,动能越大,分子接受较差解的概率越高,有助于避免算法陷入局部最优解。

在化学反应优化算法的反应过程中,分子首先处于初始状态。随后,分子经过多个转换状态和中间状态,最终达到势能最小的稳定状态,如图 2-1 所示。此过程中,中央能量缓冲区(Buffer)发挥着关键作用:分子间的相互作用可能会产生能量损失,这部分能量被存储在中央能量缓冲区中。在后续的反应中,如果分子的能量不足以完成反应,缓冲区会提供部分额外的能量,以支持反应的顺利进行。

化学反应优化算法中的能量转化遵循能量守恒定律,即热力学第一定律:在封闭系统中,能量既不会凭空产生,也不会凭空消失,而是以不同形式转化或转移。系统的总能量由分子的势能、动能和中央能量缓冲区中的能量构成。因此,为了得到稳定的低势能分子,其势能必须转化为动能或转移到中央能量缓冲区中。




图 2-1 化学反应过程中的分子势能走势图

2.1.2 四种基本反应操作

化学反应优化算法通过模拟化学反应中分子的行为来解决优化问题。该算法定义了四种基本反应类型：对墙无效碰撞反应、分解反应、分子间无效碰撞反应以及合成反应。这些反应根据参与分子的数量可分为两类：单分子反应和多分子反应，其中多分子反应通常假设为双分子反应。由于对墙无效碰撞和分子间无效碰撞对分子结构的改变较小，因此它们通常用于轻微调整分子的结构来细化搜索过程；而分解反应和合成反应对分子结构的改变较大，通常用于探索解空间中更广阔的区域。具体描述如下：

(1) 对墙无效碰撞反应

如图 2-2 所示，对墙无效碰撞反应指的是分子与容器壁发生碰撞后反弹回来。




图 2-2 对墙无效碰撞反应

本反应通常不会引起分子结构的显著变化，而是使分子获得一个新的邻域结构。假设原分子结构为 ω ，与墙壁碰撞后分子结构变为 ω' ，其满足下列关系：

$$\omega' = Neighbor(\omega) \quad \text{公式(2-1)}$$

其中， $Neighbor(\cdot)$ 被称为邻域函数，用来生成当前分子 ω 邻域内的新分子 ω' 。将得到的新分子 ω' 作为输入，通过目标函数 $f(\cdot)$ 计算得到其势能值 $PE_{\omega'} = f(\omega')$ 。为使该化学反应成功进行，必须满足以下条件：

$$PE_{\omega} + KE_{\omega} \geq PE_{\omega'} \quad \text{公式(2-2)}$$

其中， PE_{ω} 和 KE_{ω} 分别代表原分子的势能和动能。在碰撞过程中分子的部分动能会转移到中央能量缓冲区中：

$$Buffer' = Buffer + (PE_{\omega} + KE_{\omega} - PE_{\omega'}) \times (1 - q) \quad \text{公式(2-3)}$$

根据能量守恒定律，可以得到新分子的动能为：

$$KE_{\omega'} = (PE_{\omega} + KE_{\omega} - PE_{\omega'}) \times q \quad \text{公式(2-4)}$$

其中， $q \in [KELossRate, 1]$ ， $KELossRate$ 为分子动能损失率常数。

(2) 分解反应

如图 2-3 所示，分子碰撞到墙壁后裂解为多个分子，通常假设单个分子仅分裂为两个分子，即 $\omega \rightarrow \omega'_1 + \omega'_2$ 。




图 2-3 分解反应

当满足以下条件时，分解反应得以进行：

$$PE_{\omega} + KE_{\omega} \geq PE_{\omega'_1} + PE_{\omega'_2} \quad \text{公式(2-5)}$$

其中， PE_{ω} 和 KE_{ω} 分别代表原始分子的势能和动能， $PE_{\omega'_1}$ 和 $PE_{\omega'_2}$ 是两个新分子的势能，新分子的动能为：

$$KE_{\omega'_1} = temp_1 \times k \quad \text{公式(2-6)}$$

$$KE_{\omega'_2} = temp_1 \times (1 - k) \quad \text{公式(2-7)}$$

$$temp_1 = PE_{\omega} + KE_{\omega} - PE_{\omega'_1} - PE_{\omega'_2} \quad \text{公式(2-8)}$$

其中 k 是在 $[0,1]$ 区间均匀产生的随机数，用于给新分子随机分配动能。分解后多分子的能量可能大于分解前单分子的总能量，即 $temp_1$ 可能小于 0。为弥补能量可能出现的不足，可以从中央能量缓冲区借用能量，以支持分解过程的进行，此时改用以下公式进行判断：

$$PE_{\omega} + KE_{\omega} + Buffer \geq PE_{\omega'_1} + PE_{\omega'_2} \quad \text{公式(2-9)}$$

如果中央能量缓冲区能提供足够的能量，反应就能成功发生，此时新分子的动能为：

$$KE_{\omega'_1} = (temp_1 + buffer) \times m_1 \times m_2 \quad \text{公式(2-10)}$$

$$KE_{\omega'_2} = (temp_1 + buffer) \times m_3 \times m_4 \quad \text{公式(2-11)}$$

其中， $m_1 \sim m_4$ 是区间 $[0,1]$ 内独立均匀分布的随机数。由于 $buffer$ 一般情况下比较大，使用 $m_1 \times m_2$ 和 $m_3 \times m_4$ 来控制新分子的动能，避免其值过大。

(3) 分子间无效碰撞反应

如图 2-4 所示，分子间无效碰撞反应是指两个分子相互碰撞，即 $\omega_1 + \omega_2 \rightarrow \omega'_1 + \omega'_2$ 。碰撞后两分子结构均仅发生轻微的改变，新分子仍从原分子的邻域内产生。




图 2-4 分子间无效碰撞反应

假设反应前分子的结构为 ω_1 和 ω_2 ，两分子碰撞后分子结构变为 ω'_1 和 ω'_2 ，为使该化学反应成功进行，必须满足以下条件：

$$PE_{\omega_1} + PE_{\omega_2} + KE_{\omega_1} + KE_{\omega_2} \geq PE_{\omega'_1} + PE_{\omega'_2} \quad \text{公式(2-12)}$$

其中， PE_{ω_1} 和 PE_{ω_2} 是原始分子的势能， KE_{ω_1} 和 KE_{ω_2} 是原始分子的动能， $PE_{\omega'_1}$ 和 $PE_{\omega'_2}$ 是碰撞后新分子的势能，新分子的动能为：

$$KE_{\omega'_1} = temp_2 \times p \quad \text{公式(2-13)}$$

$$KE_{\omega'_2} = temp_2 \times (1 - p) \quad \text{公式(2-14)}$$

$$temp_2 = (PE_{\omega_1} + PE_{\omega_2} + KE_{\omega_1} + KE_{\omega_2}) - (PE_{\omega'_1} + PE_{\omega'_2}) \quad \text{公式(2-15)}$$

其中， p 是一个从区间 $[0,1]$ 中随机生成的值。分子间无效碰撞反应可以看作是两个分子分别与墙壁发生无效碰撞反应。然而，分子间无效碰撞反应没有能量损失，因此该反应生成的新分子通常具有更高的动能，从而避免了因分子动能不足而导致分子陷入局部最优。

(4) 合成反应

如图 2-5 所示，合成反应是指多个分子（假设两个）相互碰撞然后结合在一起，即 $\omega_1 + \omega_2 \rightarrow \omega'$ 。




图 2-5 合成反应

为使合成反应成功进行，必须满足以下条件：

$$PE_{\omega_1} + PE_{\omega_2} + KE_{\omega_1} + KE_{\omega_2} \geq PE_{\omega'} \quad \text{公式(2-16)}$$

其中， PE_{ω_1} 和 PE_{ω_2} 是两个原始分子的势能， KE_{ω_1} 和 KE_{ω_2} 是动能，新分子的动能更新为：

$$KE_{\omega'} = (PE_{\omega_1} + PE_{\omega_2} + KE_{\omega_1} + KE_{\omega_2}) - PE_{\omega'} \quad \text{公式(2-17)}$$

2.1.3 实数编码化学反应优化算法

Lam 等人在 2012 年提出了实数编码化学反应优化算法(Real-Coded Chemical Reaction Optimization,RCCRO)^[19]，该算法通过扩展传统的化学反应优化算法来解决连续优化问题。RCCRO 保留了原框架中的四种基本化学反应操作，并对其进行了适应性修改，以适应连续解空间的搜索需求。具体而言，算法通过引入基于高斯分布的扰动机制来实现邻域搜索。对于分子 ω 在第 i 维邻域搜索得到的新解由以下公式产生：

$$\omega'(i) = N(\omega(i)) = \omega(i) + \mathcal{N}(0, \sigma^2) \quad \text{公式(2-18)}$$

其中， $\mathcal{N}(0, \sigma^2)$ 表示均值为 0、方差为 σ^2 的高斯随机数。具体算法如下：

算法 2-1 RCCRO 算法

输入：初始分子集大小 $popSize$, 函数评估次数上限 $maxFEs$, 碰撞率 $collRate$, 分解阈值 α , 合成阈值 β

输出：最优分子 $bestMol$

- 1) 初始化分子集 P
 - 2) $FE \leftarrow 0$
 - 3) while $FE < maxFEs$ do
 - 4) $t \leftarrow \text{random}(0, 1)$
 - 5) if $t > collRate$ then //单分子反应
 - 6) $w \leftarrow$ 分子集 P 随机选取一个分子
 - 7) if w 在最近 α 次更新中没有找到更好的解 then
 - 8) $w'_1, w'_2, Success \leftarrow \text{decompose}(w)$
 - 9) if $Success$ then
 - 10) 从分子集 P 移除分子 w , 并将 w'_1, w'_2 添加至该分子集
 - 11) else
 - 12) $w' \leftarrow \text{ineff_coll_on_wall}(w)$
-

```

13)   else    //多分子反应
14)        $w_1, w_2 \leftarrow$  从分子集  $P$  随机选取两个分子
15)       if  $w_1.KE \leq \beta$  and  $w_2.KE \leq \beta$  then
16)            $w', Success \leftarrow \text{synthesis}(w_1, w_2)$ 
17)           if  $Success$  then
18)               从分子集  $P$  移除分子  $w_1, w_2$ , 并将  $w'$  添加至该分子集
19)       else
20)            $w_1', w_2' \leftarrow \text{inter\_ineff\_coll}(w_1, w_2)$ 
21)       更新全局最优解  $bestMol$ 
22)   end while
23)   return  $bestMol$ 

```

在 RCCRO 算法中，整体流程分为两大类反应：单分子反应和双分子反应，其选择依据为预先设定的碰撞率。对于单分子反应，如果分子在连续 α 次更新均未能获得更优解，则触发分解反应（步骤 8），此时对原分子部分维度施加扰动，从而生成两个新分子；否则，将执行对墙无效碰撞反应（步骤 12），即在单一维度上进行邻域搜索以微调解。对于双分子反应，首先检查参与反应分子的动能状态；若两个分子均处于低动能状态，则通过合成反应（步骤 16）生成新分子。在合成反应中，新分子每个维度的值是随机从父代分子的对应维度中挑选而来，也就是说，每个维度上父代的值被选中的机会是均等的；否则，采用双分子无效碰撞策略（步骤 20），使两分子各自在某一维度上进行邻域搜索。

在算法中，每进行一次化学反应生成新分子时，算法都会使用目标函数计算其势能，这就构成了一次函数评价（Function Evaluations, FE ）。初始时 FE 设为 0，之后每生成新解并计算新势能时， FE 都会自动增加 1。这一过程持续进行，直至 FE 达到预设的最大评价次数 $maxFEs$ ，算法则在此时终止，并返回最优解。

此外，文中还提出了一种自适应方案 RCCRO4，通过在固定迭代间隔内逐步减小搜索步长 σ 来实现算法的自适应调整。具体来说，每隔 Δ 次函数评估，步长 σ 会按以下公式更新：

$$\sigma \leftarrow \sigma \times \theta \quad \text{公式(2-19)}$$

其中， θ 是一个小于 1 的固定因子（通常设置为 0.99）， Δ 是一个固定的迭代间隔（通常设置为 100 次函数评价）。这种指数递减的方式可以避免过于激进的步长调整，从而在搜索过程中逐步细化搜索范围。

在优化过程中，若某个分子的某个维度超出了其对应的上下界，则需要通过边界处理来调整至可行区间。在文中的基本方案 RCCRO1 中，对分子 m 的第 i

维值 m_i ，边界处理使用反射策略（Reflecting Scheme,RS）：

$$m_i = \begin{cases} 2l_i - m_i & \text{if } m_i < l_i \\ 2u_i - m_i & \text{if } m_i > u_i \\ m_i & \text{if } l_i \leq m_i \leq u_i \end{cases} \quad \text{公式(2-20)}$$

为了确保 m_i 最终落入 $[l_i, u_i]$ 区间，可能需要多次应用上述公式。此外，为了避免反射策略将解过度推离边界，RCCRO2 算法在边界处理中采用了混合策略（Hybrid Scheme,HS）：

$$m_i = \begin{cases} l_i & \text{if } t \leq 0.5 \text{ and } m_i < l_i \\ u_i & \text{if } t \leq 0.5 \text{ and } m_i > u_i \\ 2l_i - m_i & \text{if } t > 0.5 \text{ and } m_i < l_i \\ 2u_i - m_i & \text{if } t > 0.5 \text{ and } m_i > u_i \end{cases} \quad \text{公式(2-21)}$$

其中 t 为区间 $[0,1]$ 的随机数。该策略结合了吸收和反射两种方法：当 m_i 超出边界时，根据一定的随机概率，可能直接将 m_i 设为对应的边界值（吸收），或者采用反射策略进行修正，从而更灵活地保持边界附近的搜索空间。鉴于第三章的核心在于通过优化簇中心来实现聚类，而簇中心不宜位于边界上，因此在第三章的改进方案中我们引入了反射策略。

尽管 RCCRO 在连续优化问题中展现了优异的性能，但其仍然存在一些明显局限性。最突出的问题在于 RCCRO 需要设置大量的超参数，且其性能对这些参数的设置极为敏感。不同类型的优化问题往往需要不同的参数配置，使得调参过程变得极为繁琐和耗时。更为关键的是，RCCRO 无法根据具体问题的特性自适应调整参数，这种对人工调参的依赖不仅增加了使用成本，还降低了算法的通用性和鲁棒性，限制了其在复杂实际问题中的应用潜力。

针对 RCCRO 中参数调优困难的问题，Lam 等人于 2015 年提出了自适应化学反应优化算法^[21]（Adaptive Chemical Reaction Optimization,ACRO）作为 RCCRO 的一大改进，其将原有的八个参数概括为三大类：能量相关参数、反应相关参数和实数编码相关参数。能量相关参数包括初始动能（*iniKE*）、初始中央能量缓冲区（*iniBuffer*）和分子动能损失率常数（*KELossRate*）。初始动能根据初始分子集的势能差异自适应设定：

$$iniKE = (PE_{\omega_l} - PE_{\omega_s}) \times iniPopSize \quad \text{公式(2-22)}$$

其中 PE_{ω_l} 和 PE_{ω_s} 分别表示初始分子集中最大势能和最小势能。为了抑制早期的分解反应，ACRO 将中央能量缓冲区的初始值设置为零。分子动能损失率常数则设计为每个分子的独有属性，其值由修正的折叠正态分布生成：

$$KELossRate = |N(0, 0.3^2)| \quad \text{公式(2-23)}$$

其中 $N(0, 0.3^2)$ 表示均值为 0、标准差为 0.3^2 的正态分布。

反应相关参数用于控制四种基本反应的发生频率。ACRO 通过引入新参数—

变化率(*ChangeRate*)来替代原有的分解阈值(*DecThres*)和合成阈值(*SynThres*), 并通过分子集大小反馈机制自适应调整反应的发生概率:

$$f_{pop} = \frac{curPopSize - iniPopSize}{iniPopSize} \quad \text{公式(2-24)}$$

curPopSize 表示当前分子集大小, *iniPopSize* 是初始分子集大小。基于 f_{pop} 得到分解反应的概率 (f_{dec}) 和合成反应的概率 (f_{syn}) 分别为:

$$f_{dec} = \frac{1}{2} \times (1 - f_{pop}) \quad \text{公式(2-25)}$$

$$f_{syn} = 1 - f_{dec} = \frac{1}{2} \times (1 + f_{pop}) \quad \text{公式(2-26)}$$

实数编码相关参数用于控制连续优化问题中的搜索步长 (σ , *stepSize*)。初始搜索步长根据解空间上下界自适应设定:

$$stepSize_{init,i} = \frac{Bound_{upper,i} - Bound_{lower,i}}{2} \quad \text{公式(2-27)}$$

其中 $Bound_{upper,i}$ 和 $Bound_{lower,i}$ 分别表示第 i 个变量的上界和下界。引入 1/5 成功法则来动态调整搜索步长, 具体代码实现如下:

算法 2-2 步长更新策略

输入: 当前搜索步长 *stepSize*, 当前函数评估次数 *FE*, 更新间隔 n

输出: 更新后的新步长 *stepSize*

- 1) if $FE \bmod n == 0$ then
 - 2) if 前 $10n$ 次更新中成功的次数超过 $2n$ 次 then
 - 3) $stepSize \leftarrow stepSize / 0.85$
 - 4) else
 - 5) $stepSize \leftarrow stepSize \times 0.85$
 - 6) end if
 - 7) return *stepSize*
-

2.1.4 算法特点

相较于传统的遗传算法和粒子群优化算法, 化学反应优化算法凭借其创新的能量调控机制和多样化的搜索策略, 在处理复杂优化问题时展现出了显著的优势, 如组合优化问题^[34]、任务调度问题^[35]等。这些问题通常具有庞大的解空间和多峰特性, 传统算法往往难以在有限时间内找到满意的解。而化学反应优化算法通过其独特的优化机制, 能够很好地应对这些挑战。具体来说, 化学反应优化算法引入了动能作为候选解跳出局部最优的能力指标。当分子的动能较高时, 算法能够

接受较差的解，从而跳出局部最优；当动能较低时，则聚焦于已有解的优化，强化局部搜索的深度。这种基于能量的动态调控，使得化学反应优化算法能够在全局搜索与局部优化之间实现自然的平衡。此外，化学反应优化算法中的能量缓冲区设计进一步增强了该算法的全局搜索能力：作为一个能量储备池，能量缓冲区为分子在需要时提供额外的能量支持，帮助其跳出局部最优区域，提高找到全局最优解的概率。

在实际应用中，化学反应优化算法的多种化学反应算子也为其带来了极高的灵活性。例如，对墙无效碰撞等局部搜索操作能够对当前解进行精细调整，而分解和合成反应等全局搜索操作则推动算法探索新的解空间区域。这种多样化的操作方式使得化学反应优化算法能够根据问题的具体特性调整搜索策略，从而在面对各种复杂优化问题时更具优势。

聚类问题本质上是一个优化问题，其目标是将相似的数据点划分到相同的簇中。然而，由于存在大量局部最优解，传统聚类算法如 **KMeans** 容易陷入局部最优。与此相比，化学反应优化算法凭借上述特性，能够在解空间中灵活跳跃，有效避免陷入局部最优。因此，使用化学反应优化算法来解决聚类问题是一个值得探索且具有潜力的研究方向。

2.2 聚类

2.2.1 聚类综述

根据数据在聚类中的积聚规则以及应用这些规则的方法，已经有多种聚类方法被提出和研究^[36]，大体可以分为基于划分、基于层次、基于密度以及基于网格的聚类算法。

(1)基于划分的聚类算法^[37]：基本思想是将数据集划分为若干互不重叠的簇。这类算法简洁、高效、时间复杂度较低。然而，不能保证解是全局最优解，结果很大程度上受到初始中心点的影响，同时还需要预设簇的数量。

(2)基于层次的聚类算法^[38]：层次聚类算法建立一个嵌套的聚类层次，可以是自下而上的（凝聚性）或自上而下的（分裂性）。凝聚性方法从每个数据点作为独立簇开始，然后逐步合并最相似的簇。依据相似度的计算方式，常见方法如下：
1、**Single-linkage**：簇间距离定义为两簇中最短的点对间距离。
2、**Complete-linkage**：簇间距离定义为两簇中最远的点对间距离。
3、**Average-linkage**：簇间距离定义为两簇中所有点对之间的平均距离。
分裂性方法从所有数据点作为一个整体的簇开始，然后逐渐细分。这类聚类算法计算的复杂度相对较高、聚类结果容易形成链条状进而导致聚类的精度下降。

(3)基于密度的聚类算法^[8,39]：基于密度的聚类算法将数据点密集的区域视为簇，而低密度区域的数据点通常被视为噪声或边界点。只要邻域中的密度超过某个阈值，则把该点归到离其最近的类中。基于密度的聚类算法可以发现任意形状的簇，且对噪声数据不敏感。然而其结果与参数设置有很大关系，且对不平衡数据集的聚类效果较差。

(4)基于网格的聚类算法：将整个数据空间分割成小的网格区域，然后将数据点映射到对应的网格单元中。聚类的过程主要依赖于这些网格单元的特性。这种方法的计算效率通常较高，因为它的时间复杂度主要与网格单元的数量相关，而不是直接依赖于数据点的总数。

2.2.2 聚类有效性指标

聚类有效性指标常用来评估聚类质量的好坏，主要分为三种类型：内部有效性指标、外部有效性指标和相对有效性指标。

(1) 内部有效性指标

内部有效性指标仅基于数据本身的特性来评估聚类结果，无需借助外部标签信息。戴维斯-博尔丁指数(Davies-Bouldin Index,DBI)便是其中常用的一种指标，其定义为：

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{\sigma_i + \sigma_j}{\|\mu_i - \mu_j\|_2} \right) \quad \text{公式(2-28)}$$

其中， k 为簇的总数， σ_i 表示第 i 个簇中所有样本点到其簇中心的平均距离，而 $\|\mu_i - \mu_j\|_2$ 是两个簇中心之间的欧氏距离。DBI 值越小，说明各簇内部更加紧凑且簇间分离越明显，聚类效果也就越优。

(2) 外部有效性指标

外部有效性指标利用预先标定的类别标签来衡量聚类结果与真实类别之间的一致性。常见的外部有效性指标包括兰德指数 (Rand Index,RI)、调整兰德指数 (Adjusted Rand Index,ARI)、标准化互信息 (Normalized Mutual Information,NMI) 。

给定一个聚类结果，我们可以将样本对分为四类，其中 a 表示真实标签与聚类结果均为同一类的样本对数量， b 表示真实标签与聚类结果均为不同类的样本对数量， c 表示真实标签中为同一类但聚类结果中为不同类的样本对数量， d 表示真实标签中为不同类但聚类结果中为同一类的样本对数量。基于上述定义，RI 的计算方式如下：

$$RI = \frac{a + b}{a + b + c + d} \quad \text{公式(2-29)}$$

调整兰德指数是对兰德指数的调整,考虑了随机因素的影响,其计算公式为:

$$ARI = \frac{RI - E[RI]}{\max(RI) - E[RI]} \quad \text{公式(2-30)}$$

其中, $E[RI]$ 表示在随机情况下兰德指数的期望值, $\max(RI)$ 表示兰德指数的最大可能值。

标准化互信息的计算公式为:

$$NMI = \frac{MI(U, V)}{\max(H(U), H(V))} \quad \text{公式(2-31)}$$

其中, $MI(U, V)$ 是真实标签 U 和聚类结果 V 之间的互信息, $H(U)$ 和 $H(V)$ 分别是 U 和 V 的熵。

2.3 化学反应优化聚类

化学反应优化算法与聚类的结合是通过将 CRO 的全局搜索能力与聚类任务的需求相结合,提升聚类结果的准确性和鲁棒性。现有研究主要通过以下两种思路将 CRO 应用于聚类问题。

2.3.1 直接优化聚类中心

聚类可以视为一个连续优化问题,其目标是 최소화数据点与其所属簇中心之间的距离。假设给定一个数据集 $X = \{x_1, x_2, \dots, x_n\} \subset \mathbb{R}^d$ 和预设簇数 k , 可以将目标函数定义为如下形式:

$$O = \sum_{i=1}^k \sum_{x \in C_i} dis(x, \mu_i) \quad \text{公式(2-32)}$$

其中, $\mu_i \in \mathbb{R}^d$ 表示第 i 个簇的簇心, C_i 是第 i 个簇中包含的数据点集合, $dis(x, \mu_i)$ 是数据点 x 与簇中心 μ_i 之间的距离。通过迭代更新聚类中心, 以期找到一组簇中心 $\mu_1, \mu_2, \dots, \mu_k$, 최소화目标函数 $O(\mu_1, \mu_2, \dots, \mu_k)$ 。

每个聚类方案, 即 k 个簇中心可以编码为一个 $k \times d$ 维的向量, 形如:

$$s = [\mu_{11}, \mu_{12}, \dots, \mu_{1d}, \mu_{21}, \dots, \mu_{kd}] \quad \text{公式(2-33)}$$

这个编码向量直接表示了 k 个簇的质心在 d 维空间中的位置。因此, 求解聚类问题就转化为对该向量的优化, 可以通过模拟化学反应中的四种基本反应来更新和优化聚类中心。具体算法如下:

算法 2-3 RCCROC 算法^[28]

输入：数据集 X , 维度 D , 分子集大小 $popSize$, 最大评估次数 $maxFEs$

输出：全局最优分子 $bestMole$

```

1) 初始化分子集  $P$ 
2) 计算每个分子的势能  $PE$ 
3)  $bestMole \leftarrow$  最优分子
4) while  $FE < maxFEs$  do
5)   for  $i \leftarrow 1$  to  $popSize$  do
6)     生成随机数  $r_1, r_2 \in \text{rand}(0,1)$ 
7)     if  $r_1 > 0.5$  then           // 单分子反应
8)        $w \leftarrow bestMole$ 
9)       if  $r_2 > 0.5$  then
10)         $w_1', w_2' \leftarrow \text{decompose}(w)$ 
11)        评估  $w, w_1', w_2'$  的适应度, 取最优更新  $P(i)$ 
12)      else
13)         $w' \leftarrow \text{ineff\_coll\_on\_wall}(w)$ 
14)        评估  $w_1'$  与原  $w$  的适应度, 取最优更新  $P(i)$ 
15)      else           // 双分子反应
16)         $w_1 \leftarrow$  取  $P(i)$  与  $P(i+1)$  中较优者赋值
17)         $w_2 \leftarrow best\_mole$ 
18)        if  $r_2 > 0.5$  then           // 合成反应
19)           $w' \leftarrow \text{synthesis}(w_1, w_2)$ 
20)          评估  $w', w_1, w_2$  的适应度, 取最优的两分子更新  $P(i)$  和  $P(i+1)$ 
21)        else
22)           $w_1', w_2' \leftarrow \text{inter\_ineff\_coll}(w_1, w_2)$ 
23)          评估  $w_1', w_2', w_1, w_2$  的适应度
24)          取最优的两个分子更新  $P(i)$  和  $P(i+1)$ 
25)      end for
26)    更新全局最优解  $bestMole$ 
27)  end while
28) return  $bestMole$ 

```

2.3.2 混合优化聚类中心

模糊 C 均值 (Fuzzy C-means, FCM) 算法是一种柔性划分的聚类方法; 然而,

该算法对初始聚类中心高度敏感，导致聚类结果不稳定。针对这一问题，研究者提出将 CRO 与 FCM 结合^[32]，形成混合优化框架。在混合策略中，利用 CRO 的四种基本反应调整分子结构，逐步优化目标函数，以筛选出具有最小类内距离的候选中心。具体来说，对于候选解 w_i ，其势能（目标函数值）定义为：

$$F(w_i) = \frac{k}{(\sum_{j=1}^m \sum_{r=1}^n (O_r - c_{i,j})^2) + d} \quad \text{公式(2-34)}$$

其中， O_r 表示数据集中第 r 个数据点， $c_{i,j}$ 为候选解 w_i 中第 j 个簇心， n 为数据点总数， m 为候选解的簇数， k 为正的放缩系数，而 d 是一个较小的常数，用于防止分母为零。将优化得到最佳聚类中心作为 FCM 的初始值，利用 FCM 对隶属度矩阵进行迭代更新以进一步优化划分。

在原先的化学反应优化算法中，动能和能量缓冲区用于平衡局部搜索和全局搜索，帮助算法通过接受次优解跳出局部最优。然而，上述的 RCCROC 算法和 CRO-FCM 却舍弃了这些机制，转而采用贪婪策略，即只接受适应度更优的解。其次，算法在分解、合成等操作中使用了种群中的全局最优解来引导新解的生成。这种策略虽然能够显著加速收敛速度，但可能引发早熟问题。如图 2-6 所示，将算法应用于 Iris 数据集聚类时，解集的多样性指标（解向量间平均欧氏距离）在迭代过程中过早丧失，导致搜索陷入局部最优区域（蓝色实线），如图 2-7 所示。图 2-6 中的空白区域反映了分子集中所有解完全相同的情况，此时多样性为 0。而图 2-7 显示，在多样性指标首次为 0 之后，适应值的变化极其微小，几乎趋于稳定。




图 2-6 分子集多样性变化图




图 2-7 目标函数变化图

2.4 近邻关系

近邻关系广泛应用于分类、聚类^[40,41]和异常检测等任务中。通过定义实例及其邻近关系，可以更加高效地构建基于距离或相似度的算法。以下是几种常见的近邻关系及其数学定义：

(1) k 近邻

对于数据集 $X = \{x_1, x_2, \dots, x_n\}$ ， $d(x, y)$ 表示实例 x 和 y 之间的距离。实例 x 的 k 近邻集合 $N_k(x)$ 为数据集中距离 x 最近的 k 个实例所组成的集合：

$$N_k(x) = \{y \in X \mid d(x, y) \leq d(x, x^k)\} \quad \text{公式(2-35)}$$

其中， x^k 表示数据集中第 k 近的实例。

(2) 反向 k 近邻

反向 k 近邻关系刻画了实例 x 被其他实例视为邻近的程度。记 $RN_k(x)$ 为实例 x 的反向 k 近邻集合，其定义如下：

$$RN_k(x) = \{y \in X \mid x \in N_k(y)\} \quad \text{公式(2-36)}$$

即 $RN_k(x)$ 包含了所有将 x 纳入其 k 近邻集合的实例。

(3) 相互 k 近邻

相互 k 近邻关系表示两个实例 x 和 y 互为对方的 k 近邻。实例 x 的相互 k 近邻集合 $MN_k(x)$ 定义为：

$$MN_k(x) = \{y \in N_k(x) \mid x \in N_k(y)\} \quad \text{公式(2-37)}$$

即 $MN_k(x)$ 包含所有与 x 互为 k 近邻的实例。

2.5 谱分解

2.5.1 瑞利商

瑞利商^[42]广泛应用于矩阵分析、特征值问题以及优化问题中。给定一个 $n \times n$ 的实对称矩阵 A 和一个非零向量 $x \in R^n$ ，瑞利商定义为：

$$R(A, x) = \frac{x^T A x}{x^T x} \quad \text{公式(2-38)}$$

瑞利商的一个重要性质是其值与矩阵 A 的特征值密切相关：设矩阵 A 的特征值为 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ ，对于任意非零向量 $x \in R^n$ ，瑞利商满足：

$$\lambda_1 \leq \frac{x^T A x}{x^T x} \leq \lambda_n \quad \text{公式(2-39)}$$

2.5.2 图分割问题

图分割是图论研究中的一个经典问题，其核心目标是将图中的顶点划分为若干个子集，使得子集内部的连接尽可能紧密，而子集之间的连接尽可能稀疏。特别地，图的二分割问题关注的是将一个无向图 $G = (V, E)$ 划分为两个不相交的子集 A 和 $\bar{A}$ ，满足 $A \cup \bar{A} = V$ 且 $A \cap \bar{A} = \emptyset$ 。一种基础的分割方法是最小割（Minimum Cut）， $Cut(A, \bar{A})$ 的值定义为连接子集 A 和 $\bar{A}$ 之间的边的权重总和：

$$Cut(A, \bar{A}) = \sum_{v_i \in A, v_j \in \bar{A}} w_{ij} \quad \text{公式(2-40)}$$

其中， w_{ij} 是顶点 v_i 和顶点 v_j 之间边的权重。然而，最小割方法往往倾向于划分出一个规模过小的子集，这种分割结果在实际应用中通常不具有实用价值。Shi 和 Malik^[43]提出了归一化割（Normalized Cut, $NCut$ ）。归一化割不仅考虑了子集间连接的稀疏性，还引入了各自内部节点的度之和作为归一化因子，有效解决了过小子集的问题。具体地，归一化割被定义为：

$$NCut(A, \bar{A}) = \frac{Cut(A, \bar{A})}{vol(A)} + \frac{Cut(A, \bar{A})}{vol(\bar{A})} \quad \text{公式(2-41)}$$

$$vol(A) = \sum_{v_i \in A} d_i \quad \text{公式(2-42)}$$

其中 d_i 是顶点 v_i 的度。为了求解归一化割问题，可以将其转化为与拉普拉斯矩阵相关的优化问题。拉普拉斯矩阵 L 定义为：

$$L = D - W \quad \text{公式(2-43)}$$

其中， $D = \text{diag}(d_1, d_2, \dots, d_n)$ 是度矩阵， W 是邻接矩阵。

归一化割问题是一个 NP-Hard 问题，想要直接求解其最优解非常困难。为简化它，常采用连续松弛方法，将离散约束放宽到连续域中，从而转化为一个广义特征值问题，再通过求解特征向量来获得问题的近似解。为实现这一过程，设计了一种指示向量 $f = (f_1, f_2, \dots, f_n)$ 用来表征每个节点在最终分割中的归属情况，如下所示：

$$f_i = \begin{cases} \sqrt{\frac{vol(\bar{A})}{vol(A)}} & \text{if } v_i \in A \\ -\sqrt{\frac{vol(A)}{vol(\bar{A})}} & \text{if } v_i \in \bar{A} \end{cases} \quad \text{公式(2-44)}$$

通过这种指示向量的设计，归一化割的目标函数可以转化为与拉普拉斯矩阵 L 相关的形式。对于任意向量 $f = (f_1, f_2, \dots, f_n)^T$ ，有：

$$f^T L f = \frac{1}{2} \sum_{i,j=1}^n w_{ij} (f_i - f_j)^2 \quad \text{公式(2-45)}$$

由于 f_i 和 f_j 的取值取决于顶点 v_i 和 v_j 是否属于同一个子集，如果 v_i 和 v_j 属于同一个子集（即 $v_i, v_j \in A$ 或 $v_i, v_j \in \bar{A}$ ），则 $(f_i - f_j)^2 = 0$ 。如果 v_i 和 v_j 属于不同的子集，则 $(f_i - f_j)^2$ 非零。因此，公式可以进一步推导为如下形式：

$$NCut(A, \bar{A}) = \frac{f^T L f}{f^T D f} \quad \text{公式(2-46)}$$

通过变量替换 $g = D^{\frac{1}{2}} f$ ，可以将式(2-46)的目标函数转化为瑞利商的形式：

$$NCut(A, \bar{A}) = \frac{g^T D^{-\frac{1}{2}} L D^{-\frac{1}{2}} g}{g^T g} = \frac{g^T L_{sym} g}{g^T g} \quad \text{公式(2-47)}$$

因此最小化 $NCut(A, \bar{A})$ 等价于求解 L_{sym} 的最小特征值。然而，由于 L_{sym} 是对称半正定矩阵，其最小特征值为 0，对应的特征向量为 $D^{\frac{1}{2}} \mathbf{1}$ ，其中 $\mathbf{1}$ 是全 1 的列向量，这一特征向量与分割问题无关，因为它表示所有节点属于同一个子集的情况。因此最小化 $NCut(A, \bar{A})$ 等价于求解 L_{sym} 的第二小特征值。

2.6 实验环境与数据

2.6.1 实验环境

本文所涉及到的算法均在 Python 3.11 上实现，实验环境为 AMD Ryzen 5 2500U 2.00 GHz CPU, 16G RAM, 操作系统为 Microsoft Windows 10 企业版 LTSC。

2.6.2 实验数据

为了测试第三章改进的实数编码化学反应优化算法处理连续问题的性能,本研究基于文献^[44]提出的基准测试函数展开实验。该测试集依据函数特性划分为三类:(1)高维单峰函数($f_1 \sim f_7$)为 30 维且仅含单一全局最优解。(2)高维多峰函数($f_8 \sim f_{13}$)同为 30 维但具有多个局部最优解。(3)低维多峰函数($f_{14} \sim f_{23}$)维数在 2-6 之间,虽维度较低却因密集分布的局部最优解形成强欺骗性。

实验从上述三类测试函数中选取具有代表性的函数以评估改进算法的性能:

(1)高维单峰类选取 $f_1 \sim f_4$ 共 4 个函数,来验证算法在高维空间中的全局收敛效率与局部搜索精度。

(2)高维多峰类选取 f_8 、 f_{10} 、 f_{11} 模拟高维复杂场景,旨在检验算法在高维空间中面对多个局部最优时的全局搜索能力和跳出局部最优的能力。

(3)低维多峰类选取 f_{16} 、 f_{18} 、 $f_{21} \sim f_{23}$,旨在检验算法在低维空间中面对多个局部最优时的全局搜索能力和跳出局部最优的能力。与高维多峰类不同,低维多峰类关注较低维度的场景,虽然维度较低,但多峰特性依然使得搜索任务具有挑战性。

上述共计 12 个测试函数的详细信息,包括其数学表达式、维度、各维取值空间和最小值等信息见表 2-1。

表 2-1 相关测试函数的详细信息

表达式	维数	搜索范围	最小值
$f_1(x) = \sum_{i=1}^n x_i^2$	30	$[-100,100]^n$	0
$f_2(x) = \sum_{i=1}^n x_i + \prod_{i=1}^n x_i $	30	$[-10,10]^n$	0
$f_3(x) = \sum_{i=1}^n \left(\sum_{j=1}^i x_j \right)^2$	30	$[-100,100]^n$	0
$f_4(x) = \max\{ x_i , 1 \leq i \leq n\}$	30	$[-100,100]^n$	0
$f_8(x) = \sum_{i=1}^n [-x_i \sin(\sqrt{ x_i })]$	30	$[-500,500]^n$	- 12569.49
$f_{11}(x) = \frac{1}{4000} \sum_{i=1}^n x_i^2 - \prod_{i=1}^n \cos\left(\frac{x_i}{\sqrt{i}}\right) + 1$	30	$[-600,600]^n$	0

$f_{16}(x) = 4x_1^2 - 2.1x_1^4 + \frac{1}{3}x_1^6 + x_1x_2 - 4x_2^2 + 4x_2^4$	2	$[-5,5]^n$	-1.0316
$f_{18}(x) = [1 + (x_1 + x_2 + 1)^2(19 - 14x_1 + 3x_1^2 - 14x_2 + 3x_2^2)] \times [30 + (2x_1 - 3x_2)^2(18 - 32x_1 + 12x_1^2 + 48x_2 - 36x_1x_2 + 27x_2^2)]$	2	$[-2,2]^n$	3
$f_{21}(x) = -\sum_{i=1}^5 [(x - a_i)(x - a_i)^T + c_i]^{-1}$	4	$[0,10]^n$	-10.1532
$f_{22}(x) = -\sum_{i=1}^7 [(x - a_i)(x - a_i)^T + c_i]^{-1}$	4	$[0,10]^n$	-10.4028
$f_{23}(x) = -\sum_{i=1}^{10} [(x - a_i)(x - a_i)^T + c_i]^{-1}$	4	$[0,10]^n$	-10.5363

为了验证改进的实数编码化学反应优化算法处理聚类问题的性能,采用了 15 个 UCI 数据集,分别是 Iris、Heart、Wine、Seeds、Banknote、Breast Cancer、Pima、Wholesale、Glass、Balance、Zoo、Wdbc、Ecoli、Ionosphere、Blood, 各个数据集的详细信息如表 2-2 所示。


表 2-2 涉及的 UCI 数据集相关信息

数据集	数据集规模	维数	类别数
Iris	150	4	3
Heart	270	13	2
Wine	178	13	3
Seeds	210	7	3
Banknote	1372	4	2
Breast Cancer	683	9	2
Pima	768	8	2
Wholesale	440	7	3
Glass	214	9	6
Balance	625	4	3
Zoo	101	15	7
Wdbc	569	30	2
Ecoli	327	7	5
Ionosphere	351	344	2
Blood	748	4	2


表 2-3 涉及的合成数据集相关信息

数据集	数据集规模	类别数
Flame	240	2
Aggregation	788	7
Jain	373	2
Compound	399	6
SmileFace	644	4
Spiral	312	3
R15	600	15
Zelnik2	303	3
Zelnik4	622	5
Elliptical_10_2	500	10
Diamond9	3000	9
Complex9	3031	9


第四章使用了 12 个非凸数据集来测试算法性能，可从 <https://cs.uef.fi/sipu/datasets/>和 <https://github.com/milaan9/Clustering-Datasets> 获取，包括 Flame、Aggregation、Jain、Compound、Spiral、SmileFace、R15、Zelnik2、Zelnik4、Diamond9、Complex9、Elliptical_10_2，各个数据集的详细信息如表 2-3 所示，数据集具体形状和真实簇的分布情况如图 2-8 所示。




Flame




Aggregation




Jain



Compound



SmileFace



Spiral




图 2-8 合成数据集

2.7 本章小结

本章主要分为六个部分。第一部分介绍了化学反应优化算法的基本原理及其四种基本反应类型，详细阐述了实数编码化学反应优化算法及其改进版本，最后分析了该算法的特点及其相较传统元启发式算法的优势；第二部分概述了常见的聚类方法，介绍了聚类的有效性评价指标；第三部分详细阐述了现有基于化学反应优化的聚类算法及其局限性；第四部分介绍了邻近关系的相关概念；第五部分探讨了谱分解技术，包括瑞利商和图的二分割问题；最后，本章介绍了实验环境和数据集，为后续评估算法性能奠定基础。

第三章 基于改进实数编码化学反应优化的聚类算法

在基于化学反应优化的聚类框架中，算法通过迭代优化簇中心（表示为 $k \times d$ 维向量）来逼近最优的聚类划分。然而，随着数据维度的增加，局部最优解的数量显著增多。尽管化学反应优化算法具备一定的全局搜索能力，但仍有可能收敛到一些较差的解。为解决这一问题，本章首先改进了基本实数编码化学反应优化算法，然后将改进后的算法应用于聚类问题，以实现数据的有效划分。

3.1 实数编码化学反应优化算法的改进

3.1.1 基于 Sine 混沌映射的初始化策略

传统的化学反应优化算法通过引入动能和中央能量缓冲区等机制，在一定程度上能够帮助算法跳出局部最优。然而，当初始分子集分布不均时，这些措施的效果会显著下降^[45]。如图 3-1 展示的是函数 F8（表 2-1）的二维切片可视化，其包含了大量局部极小值。在优化过程中，如果初始分子集能尽可能均匀地遍布整个解空间，算法将有更多机会找到全局最优解。相反，如果初始分子集聚集在某一局部区域，可能会导致后续分子集更快速地同质化，增加陷入局部最优的风险。




图 3-1 F8 测试函数图像

因此，如何使初始分子集充分覆盖整个解空间，成为提升算法性能的关键。

在低维空间中，传统的均匀初始化方法能够较好地生成分布均匀的初始分子集。但随着数据维度的增加，解空间的体积呈指数级增长，传统方法难以维持均匀分布。基于混沌映射的初始化方法通过生成分布更为均匀的初始分子集，在一

些元启发式算法的初始化阶段得到应用，如 Tian^[46]等人于 2017 年利用 Chaotic 混沌映射来初始化 PSO 的种群、Fu^[47]等人于 2024 年利用 Tent 混沌映射来初始化 Aquila 优化器的种群，使得初始解集在搜索空间中分布更均匀，有效提升了算法的性能。所以本文也打算采用这一策略生成初始分子集，为算法提供更全面的搜索起点。

混沌^[48]是一种在确定性系统中表现出的非线性现象，能够生成高度分散且多样化的序列。本文采用 Sine 混沌映射生成初始分子集，Sine 混沌映射的数学表达式如下：

$$Sine_{i+1} = \frac{a}{4} \sin(\pi Sine_i) \quad \text{公式(3-1)}$$

其中， $a \in (0,4]$ 。Sine₀是该迭代公式的起始值，在(0,1)区间内随机生成。由 Sine₀开始，通过递推可生成混沌序列。基于该混沌序列，可构造初始分子集：

$$X_i = lb_i + Sine_i \times (ub_i - lb_i) \quad \text{公式(3-2)}$$

其中， $[lb_i, ub_i]$ 表示第 i 维的搜索空间。

为验证该方法在高维空间中保持分子集分布多样性的效果，本文在 $[-100,100]$ ³⁰的搜索空间内设计了对比实验。分别采用均匀分布、Gauss 混沌映射、Piecewise 混沌映射和 Sine 混沌映射机制生成包含 100 个分子的初始分子集，通过计算分子间的欧氏距离，提取最近邻距离的均值和最小值作为评价指标。实验重复 30 次以减小随机性影响，结果如表 3-1 所示。

表 3-1 最近邻距离的统计量

	均匀分布	Gauss 混沌映射	Piecewise 混沌映射	Sine 混沌映射
Mean	327.36	324.84	328.65	400.78
Min	267.33	264.70	272.35	322.83

根据表 3-1 的数据，Sine 混沌映射在维持高维空间分布多样性方面表现出显著优势，其生成的分子集最近邻距离的均值和最小最近邻距离均显著高于其他三种方法。

尽管 Sine 混沌映射为 RCCRO 算法提供了更全面的搜索起点，但这种多样性增强仅限于算法的起始阶段，后续算法性能的表现则是更大程度取决于反应算子。然而 RCCRO 所采用的四个反应算子设计较为简单，如表 3-2 所示，导致其在解空间中的搜索能力不足，不仅使得算法难以跳出复杂的局部最优区域，还影响其收敛精度，从而限制了整体优化效果。因此，接下来将通过优化反应算子以进一步提升算法性能。

表 3-2 RCCRO 的四个基本反应操作

反应类型	表达式	来源（算法 2-1）
对墙无效碰撞	$\omega'(i) = N(\omega(i))$ 其中 <i>i</i> 是随机选择的维度索引	步骤 12
分子间无效碰撞	$\omega'_1(i) = N(\omega_1(i)), \omega'_2(j) = N(\omega_2(j))$ 其中 <i>i, j</i> 是随机选择的维度索引	步骤 20
分解反应	$\omega'_1(i) = N(\omega_1(i))$ $\omega'_2(j) = N(\omega_2(j))$ 其中 <i>i, j</i> 是随机选择的 $\frac{n}{2}$ 个维度索引	步骤 8
合成反应	$\omega'(i) = \begin{cases} \omega_1(i), & \text{if } t > 0.5 \\ \omega_2(i), & \text{otherwise} \end{cases}$ 其中 $i = 1, 2, \dots, n$	步骤 16

3.1.2 基于算术交叉的双分子无效碰撞反应

在当前 RCCRO 算法中，双分子无效碰撞反应（算法 2-1，步骤 20）与对墙无效碰撞反应（算法 2-1，步骤 12）在搜索机制上完全一致，都是通过引入随机扰动来实现解空间的局部探索。这种设计导致难以充分发挥不同算子的优势，限制了搜索的灵活性。所以一个改进方向是设计新的双分子无效碰撞反应，使其具有不同的搜索特性，从而增强算法在复杂解空间中的局部搜索能力。Duc^[24]等人提出使用中间搜索算子（Mean-Search Operator, MSO）代替双分子无效碰撞反应，该算子通过随机选择一个分子与全局最优分子进行双分子无效碰撞反应，如下所示：

$$x'_{i,k} = \begin{cases} x_{i,k} + \mathcal{N}(0, \sigma^2) \cdot x_{best,k} & \text{if } t > \alpha \\ x_{i,k} & \text{otherwise} \end{cases} \quad \text{公式(3-3)}$$

其中 t 是[0,1]区间的随机数。这一算子通过当前全局最优解 x_{best} 对高斯噪声 $\mathcal{N}(0, \sigma^2)$ 进行缩放，以实现当前解 x_i 的局部搜索。然而，这种设计存在明显不足，即扰动幅度与 x_{best} 中各个坐标的数值密切相关。如果当前解 x_i 已接近最优解，此时算法需要较小的扰动以进行精确的局部搜索。然而，由于扰动项的幅度一定程度上由 x_{best} 决定，若 x_{best} 的坐标值大，扰动幅度一般会过大，从而无法收敛。即该算子的效果高度依赖于问题全局最优解的位置，在这些全局最优解的坐标值不接近于零时，其局部搜索能力不佳。

为此，本节考虑设计新的双分子无效碰撞反应。在原先双分子无效碰撞反应中，两个分子通过邻域函数独立生成邻域解，缺乏有效的信息交互机制。算术交

又作为常用的交叉操作，在一些元启发式算法中得到应用。如在改进的粒子群优化算法(PSOCO)中，算术交叉被引入用于对粒子的历史最佳位置进行信息融合，取得了较好效果^[49]。因此，本研究提出在双分子无效碰撞反应中引入算术交叉算子^[50]，用来对两个分子进行加权平均，实现了信息的有效融合。具体来说，设参与交叉的两个分子分别为 x_i^t 和 x_j^t ，则新生成的分子为：

$$x_{i,k}^{t+1} = x_{i,k}^t \cdot r + x_{j,k}^t \cdot (1 - r) \quad \text{公式(3-4)}$$

$$x_{j,k}^{t+1} = x_{j,k}^t \cdot r + x_{i,k}^t \cdot (1 - r) \quad \text{公式(3-5)}$$

其中 $r \in [0,1]$ 是均匀分布的随机数。当 r 值接近 0.5 时，新生成的分子位于两个父代分子之间的区域，有助于在已知的良好解决方案之间进行插值搜索。当 r 值接近 0 或 1 时，新分子会更靠近其中一个父代。

引入算术交叉算子作为双分子无效碰撞反应后，其将与单分子撞墙搜索形成明显区分：前者通过基于权重的方向性搜索实现对解空间的定向探索，而后者仍保持随机、无方向性的局部扰动。

3.1.3 基于改进黄金正弦算法的合成反应

在当前 RCCRO 算法中，合成反应（算法 2-1，步骤 16）通过随机选择机制生成新解，即新解每个维度 i 上的值，随机取自 $\omega_1(i)$ 和 $\omega_2(i)$ 。这种机制实现简单，但存在一个明显的局限性：父代解在某些维度上可能具有较优的取值，而随机选择的合成方式没有加以利用这一信息，从而导致新解未能充分继承父代的优势。为此，ZhiYong^[22]等人引入正交实验设计(orthogonal experimental design, OED)，利用正交表能够系统地探索父代解中各个维度的取值组合，弥补了传统随机选择机制只依赖于简单随机选择所带来的不足。然而这种方法生成的子代解的多样性受限于父代解，如果分子集中的解过于相似，子代解也可能趋于一致，从而增加算法陷入局部最优的风险。

此外，原始的 RCCRO 算法存在一个明显的缺陷：随机选择可能导致两个低质量分子参与反应，从而生成低质量解。因此引入一个全局最优解来引导合成反应是一个有效的改进方向。近年来，随着元启发式算法的快速发展，将多种算法优势融合已成为主流趋势。通过结合不同算法的核心思想，可以有效弥补单一算法的不足，提升整体性能。如 Tien Trong^[23]等人提出用粒子群优化算法替代合成反应和分解反应，以改进原有方法的搜索能力和收敛速度。然而，这种混合算法的性能往往受到各个组成算法自身局限性的影响。粒子群优化算法的全局搜索依赖于群体中优秀个体的信息引导，虽然能快速收敛至较优区域，但这种机制容易导致粒子过早聚拢，从而丧失搜索多样性；同时，由于粒子趋同现象明显，而局

部搜索阶段缺乏足够的微调能力。因此，该混合算法的性能提升有限。

为此，本节提出将最近新提出的一种新型元启发式算法—黄金正弦算法融入到合成反应中。黄金正弦算法^[51] (Golden sine algorithm, Gold-SA) 是 Tanyildizi 等人于 2017 年提出的一种基于数学的新型元启发式算法。该算法的核心思想是正弦函数的振荡特性可以帮助算法在解空间中进行广泛的探索，同时结合黄金分割法来帮助算法逐步缩小搜索空间，可以在解空间中进行高效的搜索。Gold-SA 的核心公式如下：

$$x_{i,j}^{t+1} = \underbrace{x_{i,j}^t \cdot |\sin(r_1)|}_{\text{Part1}} - \underbrace{r_2 \cdot \sin(r_1) \cdot |\theta_1 \cdot x_{best,j}^t - \theta_2 \cdot x_{i,j}^t|}_{\text{Part2}} \quad \text{公式(3-6)}$$

其中， $x_{i,j}^t$ 表示在第 t 次迭代中，个体 i 在第 j 维的值。 $x_{best,j}^t$ 表示当前全局最优解在第 j 维的值。其中 r 为 $[0,1]$ 的随机数， r_1 和 r_2 分别 $2\pi r$ 和 πr 。该位置更新公式包含两个部分：Part1 通过 $x_{i,j}^t$ 与 $|\sin(r_1)|$ 的乘积引入了随机性，而 Part2 则利用了全局最优解的信息，其中 $E[r_2 \cdot \sin(r_1)] < 0$ ，从而在更新时引入了一个正向引导项。

整体上，该公式既能在搜索过程中对当前解进行一定程度的随机扰动，又能通过 Part2 的引导作用有效地引导解向全局最优方向调整。 θ_1 和 θ_2 是通过黄金分割法得到的系数，其计算公式如下：

$$\theta_1 = (1 - \tau) \times a + \tau \times b \quad \text{公式(3-7)}$$

$$\theta_2 = \tau \times a + (1 - \tau) \times b \quad \text{公式(3-8)}$$

式中，黄金分割系数 $\tau = (\sqrt{5} - 1)/2 \approx 0.6183$ ， a 和 b 的初始值分别设置为 $-\pi$ 和 π 。

该算法在一些问题上获得了较好的优化效果，但仍存在一些明显的局限性：在更新解时，算法仅依赖于当前全局最优解来引导搜索，可能导致解集快速同质化，增加陷入局部最优的风险。为了弥补黄金正弦算法的不足，本文借鉴粒子群优化算法中的位置更新策略，在更新速度时不仅考虑全局最优解 x_{best}^t ，还引入个体的历史最优信息 x_{pbest}^t ，从而形成多源信息引导的搜索策略。改进后的位置更新公式如下：

$$x_{i,j}^{t+1} = x_{i,j}^t \cdot |\sin(r_1)| - r_2 \cdot \sin(r_1) \cdot |\theta_1 \cdot x_{best,j}^t - \theta_2 \cdot x_{i,j}^t| + \alpha \cdot (x_{pbest,i,j}^t - x_{i,j}^t) \quad \text{公式(3-9)}$$

其中， $x_{pbest,i}^t$ 表示第 i 个个体在反应过程中的历史最优解， α 为正的权重系数，用于控制个体历史最优解对位置更新的影响。改进后的代码如下所示：

算法 3-1 IGoldSA 算法

输入：种群规模 N , 维度 D , 最大评估次数 $maxFEs$, 权重系数 α

输出：全局最优解 $best$

- 1) 初始化解集 X
 - 2) 初始化全局最优解 $best \leftarrow X$ 中的全局最优解
 - 3) 初始化历史最优解 $Pbest \leftarrow X$
 - 4) 初始化参数: $a \leftarrow -\pi, b \leftarrow \pi, FE \leftarrow 0$
 - 5) 使用式(3-7)、式(3-8)初始化 θ_1 和 θ_2
 - 6) while $FE < maxFEs$ do
 - 7) for $i \leftarrow 1$ to N do
 - 8) 使用式(3-9)更新并计算 $f(x_i)$
 - 9) if $f(x_i) < f(best)$ then
 - 10) $best \leftarrow x_i$
 - 11) $b \leftarrow \theta_2, \theta_2 \leftarrow \theta_1$, 使用式 3-7 更新 θ_1
 - 12) else
 - 13) $a \leftarrow \theta_1, \theta_1 \leftarrow \theta_2$, 使用式 3-8 更新 θ_2
 - 14) if $\theta_1 == \theta_2$ then
 - 15) $a \leftarrow \text{rand}(-\pi, 0), b \leftarrow \text{rand}(0, \pi)$
 - 16) 使用式 3-7、式 3-8 生成 θ_1 和 θ_2
 - 17) if $f(x_i) < f(Pbest_i)$ then
 - 18) $Pbest_i \leftarrow x_i$
 - 19) end for
 - 20) end while
 - 21) return $best$
-

算法的主循环由条件 while $FE < maxFEs$ 控制，其中 FE 表示评估次数， $maxFEs$ 是用户设定的最大评估次数，为一个有限正整数。每次外层循环中，内层 for 循环会遍历种群规模 N 个个体，每计算一次 $f(x_i)$ 会使 FE 增加 1，因此每次外层循环使 FE 增加 N 。经过最多 $\lceil maxFEs/N \rceil$ 次迭代， FE 将达到或超过 $maxFEs$ ，从而终止循环。

其中，IGold-SA 算法与 Gold-SA 算法的区别是 IGold-SA 算法在位置更新中考虑了个体的历史最优信息，使得当前位置向该个体历史最优方向微调(步骤8)。在每次更新完个体的位置 x_i 并计算其适应度 $f(x_i)$ 后，算法都会对比该个体当前的适应度与其历史最优适应度。如果当前解优于记录的历史最优解，便会及时更新

该个体的历史最优位置（步骤 17-18）。

3.1.4 IRCCRO 算法流程




图 3-2 IRCCRO 算法流程图

IRCCRO 算法首先利用 Sine 混沌映射生成高多样性的初始分子集合，每个分子被赋予初始的动能、由目标函数计算得到的势能及其他必要参数；在迭代过程中，系统依据预先设定的碰撞率随机决定执行单分子碰撞还是多分子碰撞；随后依据合成或分解条件，选择执行对墙无效碰撞反应、基于算术交叉的双分子无效碰撞反应、分解反应或基于改进黄金正弦算法的合成反应，以实现局部搜索与全局探索的有效结合；每次反应后，通过能量更新和解接受机制判断新解是否有效，并及时更新全局最优解、每个分子的历史最优解；当达到预定的函数评估次

数或满足收敛条件后，算法终止并输出最终的全局最优分子。具体的算法流程如图 3-2 所示。

3.2 改进实数编码化学反应优化算法在聚类上的应用

KMeans 算法的聚类效果高度依赖初始聚类中心的选择。为此，一些研究尝试先利用元启发式算法获取高质量的初始聚类中心，再将其作为 KMeans 的起点进行进一步的优化。然而，若元启发式算法已具备强大的搜索能力，再额外引入 KMeans 进行局部寻优，除加快收敛速度外，意义较小，反而无法充分体现元启发式算法在全局优化方面的优势。

3.1 节对 RCCRO 算法进行了改进，增强了其全局搜索能力和求解精度。本节直接应用该改进算法，以式(2-32)表示的误差和作为目标函数，优化簇中心以实现高效的聚类划分。

编码方案采用基于质心的实值编码。该方案在很多情况下被使用^[52,53]，具体思路是将每个簇中心表示为一个与数据特征维度一致的实数向量。假设数据集中的数据点为 d 维，且预先指定簇数为 k ，则每个分子可以被编码为一个 $d \times k$ 维的实数向量。该向量的前 d 个元素代表第一个簇中心的坐标，接下来的 d 个元素代表第二个簇中心的坐标，依此类推。例如，在三维空间 ($d=3$) 的聚类问题中，若需寻找 $k=4$ 个簇中心，则每个分子将表示为一个 12 维的向量 $m = [m_1, m_2, \dots, m_{12}]$ ，其中， $[m_1, m_2, m_3]$ 对应第一个簇中心； $[m_4, m_5, m_6]$ 对应第二个簇中心； $[m_7, m_8, m_9]$ 对应第三个簇中心； $[m_{10}, m_{11}, m_{12}]$ 对应第四个簇中心。

在使用 RCCRO 算法优化簇中心的过程中，可能会出现不恰当的聚类方案，如簇中心偏离数据实际分布范围。为此，设数据集第 i 维最小值为 $\min_i$ ，最大值为 $\max_i$ ，则每个簇中心在该维度的取值范围均设定为 $[\min_i, \max_i]$ 。对于每一维的坐标值，若其超出预先定义的上下界范围，则利用公式(2-20)对其进行反射修正。

同时，聚类过程中还可能出现部分簇中仅包含极少量数据点或完全没有数据点的情况，即出现空簇。为此，我们在每次迭代过程中均对各个簇的有效性进行检测：若检测发现某一簇中的数据点数量不足，则对该簇的簇中心进行重新初始化，直至满足最小簇规模的要求。上述修复调整机制如算法 3-2 所示：

算法 3-2 Repair 算法

输入: 数据集 $data$, 簇心 sln , 下界 lb , 上界 ub , 簇数 k , 数据维度 d , 最小簇规模 $minSize$

输出: 修复后的簇心

```

1) for  $i \leftarrow 1$  to  $d$  do
2)     while  $sln[i] < lb[i]$  or  $sln[i] > ub[i]$  do
3)         使用公式(2-20)修复  $sln[i]$ 
4)     end while
5) end for
6)  $centroids \leftarrow sln.reshape(k, d)$ 
7) while True do
8)      $clusters \leftarrow$  将数据点分配至距离最近的簇心
9)      $count \leftarrow$  每个簇包含的数据点个数
10)    if  $\min(count) \geq minSize$  then
11)        break
12)    for  $i \leftarrow 1$  to  $k$  do
13)        if  $count[i] < minSize$  then
14)             $centroids[i] \leftarrow$  随机生成新簇心
15)        end if
16)    end for
17) end while

```

算法 3-2 首先对解的各个维度进行检查, 确保其位于指定的界限内。如果超出了预定范围, 则通过公式(2-20)对其进行修正 (步骤 1-5), 该过程必然收敛。然后统计每个簇包含的数据点个数, 只有当所有簇中数据点的数量均不少于预设的最小簇规模 (本文设置为 4) 时, 算法才终止, 否则, 对于那些包含较少数据点的簇, 算法会重新随机初始化一个新的簇心 (步骤 6-17), 每次重新生成簇心后, 数据点会重新分配到最近的簇心, 随着不断地重新分配和生成新簇心的过程, 总会出现一种簇心分布使得所有簇的数据点数量满足最小规模要求, 从而使算法终止。

基于改进实数编码化学反应优化的聚类算法(Improved Real-Coded Chemical Reaction Optimization Clustering, IRCCROC)的过程如下

算法 3-3 IRCCROC 算法

输入：数据集 $data$, 簇数 k , 数据维度 d , 初始分子集大小 $popSize$, 最大函数评估次数 $maxFEs$

输出：聚类中心 m

- 1) $lb \leftarrow [], ub \leftarrow [], FE \leftarrow 0$
 - 2) $max_values \leftarrow \max(data), min_values \leftarrow \min(data)$
 - 3) for $i=1$ to k do
 - 4) $lb.append(min_values)$
 - 5) $ub.append(max_values)$
 - 6) end for
 - 7) 使用式 3-1、式 3-2 初始化分子集
 - 8) for $FE < maxFEs$ do
 - 9) $Success \leftarrow$ 使用 IRCCRO 的四个反应算子优化分子集
 - 10) if $Success$ then
 - 11) 使用算法 3-2 对更新的新分子进行修复
 - 12) 使用公式 2-32 计算修复后分子的新势能
 - 13) $res \leftarrow$ 分子集中的全局最优解
 - 14) return $res.reshape(k, d)$
-

算法 3-3 首先计算数据在各维度上的最大值与最小值，由于每个分子包含 k 个簇中心，因此需要将每个维度的上下界重复 k 次，分别构成完整的下界向量 lb 和上界向量 ub （步骤 1-6）；接着利用公式 3-1 和公式 3-2 初始化分子集，并调用 IRCCRO 算法的四个反应算子对分子集进行迭代优化（步骤 7、9）。这四个算子包括原始的对墙无效碰撞反应和原始的分解反应（表 3-2）、基于算术交叉的双分子无效碰撞反应（公式 3-4 和 3-5）以及基于改进黄金正弦算法的合成反应（公式 3-10）。如果反应成功，则使用算法 3-2 对更新后的新分子进行修复，确保其满足预设约束，并通过公式 2-32 计算修复后分子的势能（步骤 10-12）；最后，从优化结束的分子集中提取出全局最优解，将其重塑为形状为 $k \times d$ 的矩阵，作为聚类结果返回。

3.3 实验及分析

3.3.1 IRCCRO 求解连续函数的性能

为了验证改进后算法处理连续优化问题的性能，我们引入了五种算法进行对

比, 包括 RCCRO^[19]、HPCRO2^[23]、ACRO^[21]、DE^[54]、Gold-SA^[51]、IGold-SA (算法 3-1)。对比算法的相关参数均依据各自原论文中的建议进行设置。其中 IRCCRO 的算法已开源至 <https://github.com/AnonymousC2017/The-Research-on-Clustering-Algorithm-Based-on-Chemical-Reaction-Optimization>。包括 IRCCRO 在内的 6 个算法都在测试函数上独立运行了 30 次, 以消除偶然性带来的误差, 让实验结果更加精确和可靠。结果如表 3-3 所示, 表现最佳数值加粗突出显示, 表中最优数包括相同的最优结果。

表 3-3 7 种算法求解连续函数的性能 (均值)

f	RCCRO4	HPCRO2	ACRO	DE	Gold-SA	IGold-SA	IRCCRO
F1	9.61E-12	1.47E-36	2.94E-12	6.58E-06	0.00E+00	0.00E+00	0.00E+00
F2	9.48E-07	8.02E-03	5.83E-07	2.89E-04	0.00E+00	0.00E+00	0.00E+00
F3	3.16E-14	1.94E-05	4.63E-07	1.21E+04	0.00E+00	0.00E+00	0.00E+00
F4	6.82E-06	6.40E-03	4.61E-06	5.79E+00	4.66E-271	0.00E+00	0.00E+00
F8	-1.20E+04	-9.18E+03	-7.85E+03	-1.26E+04	-1.25E+04	-1.26E+04	-1.26E+04
F10	6.13E-07	4.07E-12	1.26E-08	7.14E-04	4.44E-16	4.44E-16	4.44E-16
F11	1.16E-02	2.65E-02	1.13E-01	9.05E-05	0.00E+00	0.00E+00	0.00E+00
F16	-9.67E-01	-9.99E-01	-1.00E+00	-1.01E+00	-9.39E-01	1.00E+00	-1.01E+00
F18	3.12E+00	3.00E+00	3.04E+00	3.48E+00	1.39E+01	7.81E+00	3.00E+00
F21	-9.55E+00	-9.73E+00	-9.47E+00	-8.74E+00	-7.97E+00	-9.39E+00	-1.01E+01
F22	-9.25E+00	-9.94E+00	-9.82E+00	-9.20E+00	-8.29E+00	-9.80E+00	-1.04E+01
F23	-9.18E+00	-9.96E+00	-9.20E+00	-9.23E+00	-7.82E+00	-9.98E+00	-1.03E+01
最优数	0	1	0	2	5	7	12

实验数据表明, 本文提出的 IRCCRO 算法在连续函数优化问题中展现出显著优势。具体而言, 在高维优化问题上, IRCCRO 相较于 RCCRO 及其相关改进算法表现出显著的性能提升; 在低维多峰问题中, IGoldSA 相比原始 GoldSA 取得了性能改善, 验证了本文提出对 GoldSA 改进策略的有效性。而 IRCCRO 在上述函数上的表现更为出色, 进一步凸显了其性能优势。

为了更加直观地说明算法的收敛精度和收敛效率, 图 3-3 展示了提出的 IRCCRO 算法与 RCCRO 及其改进变体在部分基准函数上的收敛曲线。




图 3-3 四种算法在部分基准函数上的收敛曲线

本文提出的改进算法从三个方面对原算法进行了优化。为了验证各项改进策略对算法性能的提升效果，设计了以下对比实验：仅采用 **Sine** 混沌映射策略的实数编码化学反应优化算法 (**cRCCRO**)、仅采用基于算术交叉的实数编码化学反应优化算法 (**acRCCRO**)、仅采用改进黄金正弦算法的实数编码化学反应优化算法 (**igRCCRO**)，并与原始实数编码化学反应优化算法 (**RCCRO4**) 进行对比。所有实验参数均与上述实验保持一致，实验结果如表 3-4 所示，表中各算法获得的最优值以加粗字体标示。通过对比分析，可以直观体现每项改进对算法性能的独立贡献及整体提升效果。

表 3-4 单一策略改进的算法结果对比（均值）

f	RCCRO4	cRCCRO	acRCCRO	igRCCRO	IRCCRO
F1	9.61E-12	5.99E-12	4.28E-12	2.20E-209	0.00E+00
F2	9.48E-07	8.54E-07	8.09E-07	1.28E-204	0.00E+00
F3	3.16E-14	9.72E-15	8.92E-15	0.00E+00	0.00E+00
F4	6.82E-06	6.58E-06	7.24E-06	0.00E+00	0.00E+00
F8	-1.20E+04	-1.20E+04	-1.22E+04	-1.22E+04	-1.26E+04
F10	6.13E-07	6.13E-07	5.42E-07	4.44E-16	4.44E-16
F11	1.16E-02	4.92E-03	6.57E-03	0.00E+00	0.00E+00
F16	-9.67E-01	-9.89E-01	-1.01E+00	-9.89E-01	-1.01E+00
F18	3.12E+00	3.09E+00	3.00E+00	3.90E+00	3.00E+00
F21	-9.55E+00	-9.82E+00	-9.80E+00	-9.40E+00	-1.01E+01
F22	-9.25E+00	-9.72E+00	-9.82E+01	-9.46E+00	-1.04E+01
F23	-9.18E+00	-9.86E+00	-9.84E+01	-9.56E+00	-1.03E+01
最优数	0	0	2	4	12

从表 3-4 可以看出，三种单一策略均能不同程度地提高算法的收敛速度和精度，而将三者融合的改进算法在所有测试函数中均展现了最优的寻优效果和较强的鲁棒性，充分证明了本文改进思路的有效性和实用价值。

3.3.2 IRCCRO 处理聚类问题的性能

我们以公式(2-32)为目标函数，通过最小化各簇内数据点到簇心的距离总和来聚类。在实验中，我们引入了五种算法进行对比，包括 KMeans++算法^[55]、IKPSO 算法^[56]、GA^[57]算法、HG-Means^[58]算法、CROC^[28]算法以及 CROKMeans^[33]算法。在每个数据集上，算法各自独立地运行 30 次。为了保证公平比较，这些元启发式算法的公共参数设置都是相同的，其中分子集规模（ N ）被设定为 10，最大函数评估次数（ $maxFEs$ ）被设定为 50000。对比算法的相关参数均依据各自原论文中的建议进行设置。实验结果如表 3-5 所示。

表 3-5 7 种算法优化目标函数的实验结果（均值）

数据集	KMeans++	IKPSO	GA	HGMeans	CROC	CROKMeans	IRCCROC
Iris	29.22	29.21	29.30	29.22	30.30	29.16	29.15
Heart	284.33	284.13	285.24	284.27	283.82	283.82	283.77
Seeds	63.28	63.23	63.87	63.28	63.22	63.19	63.16
Banknote	401.84	400.08	399.60	401.78	399.52	399.29	399.23
Breast Cancer	332.05	330.97	331.74	331.88	329.52	329.68	329.38
Parkinsons	127.71	117.30	138.41	127.23	116.37	116.90	116.33
Pima	282.71	282.37	282.62	282.68	282.05	282.08	281.91
Wine	88.74	88.68	92.01	88.70	88.72	88.66	88.57
Glass	50.65	53.15	62.43	49.89	50.85	49.96	50.20
Balance	356.00	356.66	356.78	356.03	356.49	355.96	355.96
Zoo	87.87	88.88	112.39	86.47	88.92	87.76	87.63
Wdbc	318.31	318.20	378.58	318.31	318.82	317.68	316.92
Ecoli	79.81	81.15	84.61	79.80	80.94	80.42	79.45
Ionosphere	405.05	404.98	443.10	405.05	404.56	404.12	403.46
Blood	144.66	143.15	142.58	144.53	142.56	142.61	142.54
最优数	0	0	0	2	0	1	13

从表中的实验结果可以看出，IRCCROC 算法在这些数据集上展现出显著优势。这表明，IRCCROC 通过融合元启发式算法的全局搜索能力与局部优化机制，在聚类问题中实现了更高的解质量与稳定性。

3.4 本章小结

本章将聚类问题视作优化问题，考虑直接采用实数编码化学反应优化算法来求解这一优化任务以实现聚类。针对实数编码化学反应优化算法在连续函数求解中表现出的求解精度不足和全局搜索能力较弱的问题，本文提出了针对性的改进措施。具体来说，本文首先利用 Sine 混沌映射生成初始分子集，以确保解在搜索空间内的分布具有足够的多样性；随后，通过实值遗传算法中的算术交叉操作作为双分子无效碰撞反应，并结合黄金正弦算法与粒子群优化思想对合成反应进

行优化,从而进一步增强了算法在全局探索和局部搜索方面的能力。实验结果表明,无论是在连续函数优化还是在聚类任务中,改进后的算法均取得了显著效果。

第四章 自适应化学反应优化聚类算法

4.1 引言

第三章提出使用改进的实数编码化学反应优化算法优化簇心以实现聚类，其核心思想是通过最小化数据点与簇心间的欧氏距离之和来实现划分。这种目标函数默认数据簇具有球形或凸状几何特征，对于具有复杂几何结构的非凸数据集，该算法的效果十分有限，如图 4-1 所示。此外，上述方法需要用户预先指定簇的数量，然而在实际应用中往往难以确定。针对上述问题，本章提出自适应化学反应优化聚类算法（Adaptive Chemical Reaction Optimization Clustering, ACROC）。




图 4-1 IRCCRO 算法在非凸数据集上的聚类效果

聚类分析的目标是将相似的数据点聚合成簇。在传统的层次聚类算法中，凝聚型层次聚类从每个数据点作为一个单独的簇开始，逐步合并最相似的簇，从而形成更大的簇；分裂型则从所有数据点作为一个整体簇开始，通过逐步拆分形成更小的簇。然而，两类算法的共性是单向不可逆，均缺乏对已执行操作的动态修正能力。此外，传统层次聚类通常需要预先设定簇的数量，这在实际应用中往往难以准确实现。

化学反应优化算法提供了合成反应和分解反应两种机制，与层次聚类中的合并与分裂操作具有高度的相似性。合成反应将性质相近或具有互补功能的分子结合成更大的结构，类似于凝聚型聚类的合并步骤；而分解反应则将不稳定的分子拆分为更小的单元，类似于分裂型聚类的分裂步骤。这种天然的对对应关系启发我们采用化学反应优化算法来实现聚类分析。表 4-1 列出了两者之间的关系。本章

将类簇视作分子，通过迭代执行合成、分解反应，算法在实现灵活聚类的同时实现了簇数的自适应确定。

表 4-1 聚类问题与化学反应优化算法的对应关系

聚类问题	化学反应优化算法
分裂型层次聚类	分解反应
凝聚型层次聚类	合成反应
数据点	原子
簇	分子
簇数 k	分子集大小
加权簇间近邻对数	分子的动能
簇内的离散程度	分子的势能

4.2 基于化学反应优化的双阶段自适应聚类算法

4.2.1 基于互近邻的初始分子集构建

受原子间相互作用强度(如共价键或范德华力)随距离增大而减弱的启发^[59]，我们可以将数据点视为原子，利用高斯核函数刻画其间相互作用力，即：

$$f(x_i, x_j) = \exp \left(-\frac{\|x_i - x_j\|^2}{2\sigma^2} \right) \quad \text{公式(4-1)}$$

其中， $\|x_i - x_j\|$ 表示数据点 x_i 与 x_j 间的欧式距离， σ 是核函数宽度。当两个原子间的相互作用较强时，它们更容易形成稳定的化学键。为量化这一现象，我们引入 k 近邻关系。具体而言，数据点可能与其 k 近邻建立连接。而当数据点 x_i 和 x_j 互为近邻（即 $x_i \text{ Mnn } x_j$ ）时，我们认为它们之间形成了稳定的双向连接，将它们归为同一簇。进一步地：若 $x_i \text{ Mnn } x_j$ 且 $x_j \text{ Mnn } x_z$ ，则 x_i 、 x_j 、 x_z 归属同一个簇。以下给出了一个初始分子集的构建过程，如图 4-2、表 4-2~表 4-3 所示，最终形成了 ABCD、EFGH 两个簇。在图中，虚线表示两个原子之间仅存在单向的近邻关系，而实线表示两个原子之间形成了稳定的化学键。




图 4-2 跨分子连接示例（近邻数 k 设置为 2）

表 4-2 图中数据点的距离矩阵

	A	B	C	D	E	F	G
B	13						
C	11	9					
D	10	18	12				
E	26	39	32	21			
F	33	44	37	26	8		
G	40	52	45	34	13	8	
H	16	29	23	13	10	18	24

表 4-3 数据点的近邻和互近邻关系

	A	B	C	D	E	F	G	H
KNN	DC	CA	BA	AC	FH	EG	FE	ED
MNN	DC	C	BA	A	FH	EG	F	E

根据以上描述，构建基于互近邻关系的初始分子集过程如算法 4-1 所示。

算法 4-1 构建初始分子集算法 init

输入：数据集 $D=\{x_1, x_2, \dots, x_n\}$, 近邻数 k

输出：初始分子集 A

- 1) $A \leftarrow \emptyset$
 - 2) for $i \leftarrow 1$ to n do
 - 3) $A \leftarrow A \cup \{x_i\}$
 - 4) end for
 - 5) while $|A| > 1$ do
 - 6) if $\exists G_i, G_j \in A$ and $Mnn(G_i, G_j)$ then
 - 7) $A \leftarrow A - G_i - G_j$
 - 8) $A \leftarrow A \cup \{G_i \cup G_j\}$
 - 9) else
 - 10) break
 - 11) end while
-

其中 $Mnn(G_i, G_j)$ 当且仅当 $\exists x \in G_i$ and $y \in G_j$ and $Mnn(x, y)$ 为真。

算法 4-1 描述了构建初始分子集的过程。首先，初始化一个空集合 A ，然后将每个样本 x_i 单独作为一个簇加入该集合中（步骤 1-4）。接下来，不断检查集合 A 中是否存在两个簇 G_i 和 G_j 满足 $Mnn(G_i, G_j)$ 。若找到这样的一对簇，则将它们合并为新簇加入集合 A 中，并将 G_i 和 G_j 从 A 中移除。该迭代过程持续进行，直到集合 A 中不再存在满足合并条件的簇对或者集合中只剩下一个簇为止（步骤 5-11）。这个过程集合 A 中的元素数量会严格减少。由于初始时 $|A|$ 为 n 是有限的，最多经过 $n-1$ 次迭代， $|A|$ 就会减少到 1 或者不存在满足合并条件的簇对，从而使算法终止。

在构建出初始分子集后，算法将交替执行合成反应和分解反应，实现对分子集的持续优化。通过交替进行合成与分解反应，可以在某一步出现偏差时，通过另一反应弥补，提升整体算法的鲁棒性和准确性。

4.2.2 基于谱分解的分解反应

由于初始分子集可能存在不合理的划分，或者在合成过程中可能发生不当的分子合并，因此本节考虑引入分解反应，将不合理的分子进行分解。在设计分解反应机制时，主要需解决两个关键问题：

1. 分子选择问题：我们需要一个合理的量化指标来判定哪些分子结构不够稳定，更应优先进行分解。

2. 分解策略问题：在确定待分解的分子后，如何将其有效分解为更小且更稳定的子结构成为关键。

本节将分子（簇）视为连通图，其中原子（实例）作为节点，化学键（高斯核，公式(4-1)）作为边，从而将分解问题转化为图的二分割问题。

在图的二分割问题中，核心任务是将图划分为两个子集 A 和 $\bar{A}$ ，并最小化两子集连接边权重之和 $Cut(A, \bar{A})$ 。然而，直接优化 Cut 存在明显缺陷：算法倾向于将少数孤立的节点单独划分为一个子集，而剩余节点构成另一个子集。这种极端划分的 Cut 值虽然小，但在化学分解等实际场景中往往无意义。为此，本节使用归一化割 $NCut(A, \bar{A})$ ^[43] 作为优化目标，通过顶点度之和对 $Cut(A, \bar{A})$ 进行归一化处理，从而避免算法生成孤立小簇或规模失衡的分割。

为求解归一化割的最小值，我们可以构造该图的对称归一化拉普拉斯矩阵 L_{sym} ，计算其第二小特征值 λ_2 及对应的特征向量 g 。该特征值 λ_2 可用于近似归一化割的最小值，值越小表示图具有更明显的分割结构。基于此，我们定义分子的势能为 λ_2 的倒数，即势能越大表示分子内部结构越易于分割：

$$PE(M) = \frac{1}{\lambda_2} \quad \text{公式(4-2)}$$

根据分子势能值，我们可以确定待分解的分子，接下来需要考虑如何将其分解为更小且更稳定的子结构。首先将待分解分子的特征向量 g 转换得到指示向量 f 。传统上，我们可以根据指示向量中每个分量的正负号来实现图的初步切割，即将所有正值节点归为一类，负值节点归为另一类。然而这种切割倾向于产生两个度数和相近的子图。而在实际切割问题中，度数和的平衡并不是必须的，且这种一刀切的分割会忽略数据内在结构。为此使用 KMeans($k=2$)对指示向量 f 进行调整以获得更符合实际需求的图切割^[60]。这样就可以将一个连通图分为两个子图。分解过程如算法 4-2 所示：

算法 4-2 分解反应 $\text{div}(A)$

输入：分子集 $A = \{A_1, A_2, \dots, A_n\}$

输出：更新后的分子集, 反应结果 res

- 1) $B \leftarrow$ 移除不参与分解反应的分子得到待分解分子集 // 算法 4-5 步骤 15-16
 - 2) if $|B| == 0$ then
 - 3) return False
 - 4) for each $m \in B$ do
 - 5) 计算 m 对应图的对称归一化拉普拉斯矩阵 $L_{sym} \leftarrow D^{-\frac{1}{2}} L D^{-\frac{1}{2}}$
 - 6) 求 L_{sym} 的第二小特征值 λ_2 及对应的特征向量 g
 - 7) $PE_m \leftarrow PE(m)$ // 公式 4-2
 - 8) end for
 - 9) for each $m \in B$ do
 - 10) $P_m \leftarrow \frac{PE_m}{\sum_{m \in B} PE_m}$
 - 11) end for
 - 12) 根据概率 P 选出待分解分子 $tMol$
 - 13) $f \leftarrow D^{-\frac{1}{2}} g$ // 将 $tMol$ 的特征向量 g 转换为指示向量 f
 - 14) $label \leftarrow$ 使用 KMeans 将指示向量 f 分成两簇
 - 15) 根据 $label$ 将 $tMol$ 包含的原子集合划分为两个集合 V_1 和 V_2
 - 16) 根据 V_1 、 V_2 创建新分子 mol_1 、 mol_2
 - 17) $A \leftarrow (A - \{tMol\}) \cup \{mol_1\} \cup \{mol_2\}$
 - 18) return True
-

算法 4-2 首先计算待分解分子集中每个分子的势能，具体过程为构建每个分子对应的对称归一化拉普拉斯矩阵 L_{sym} ，然后计算矩阵的第二小特征值 λ_2 及对应的特征向量 g ，利用第二小特征值 λ_2 近似归一化割的最小值，从而得到各个分子

的势能（步骤 4-8）。完成所有分子的势能计算后，采用轮盘赌策略根据势能值选择待分解的目标分子（步骤 9-12）。对于选中的分子，将其特征向量 g 转化为指示向量 f ，并将 f 输入到 KMeans 聚类算法中分成两簇。依据返回的聚类标签，构建两个新分子，并更新分子集（步骤 13-17）。

4.2.3 合成反应机制

在合成反应中，算法需要从当前分子集中选取一对分子进行反应。这一选择过程并非随机，而是基于对分子反应倾向的量化评估。从碰撞理论的视角来看，化学反应的发生依赖于分子间的碰撞，而碰撞的概率与分子之间的距离密切相关。距离越近，分子发生碰撞的可能性越高，从而提升反应发生的几率。因此，如何准确、高效地度量分子间的距离成为量化分子反应倾向（即动能）的核心。

传统的凝聚型层次聚类^[38]中常用的距离度量策略存在显著的局限性。以单链聚类为例，该方法仅关注两个簇之间最近邻点间的距离，而忽略了簇内数据点的整体分布特征。为此，我们提出了新的度量方法以更准确地量化分子间的反应倾向。

在分子系统中，当两个分子靠近时，其内部原子之间可能通过近邻关系形成跨分子连接（如图 4-2 中数据点 D 和数据点 H 之间的虚线所示）。这些跨分子连接产生的相互作用力能够反映两分子反应的可能性。为此，我们定义了加权簇间近邻对数作为动能来量化两个分子合并的倾向，计算公式如下：

$$KE(M_1, M_2) = \sum_{x_i \in M_1} \sum_{x_j \in M_2} I(x_i \in N_k(x_j) \text{ or } x_j \in N_k(x_i)) \cdot f(x_i, x_j) \quad \text{公式(4-3)}$$

其中， M_1 和 M_2 分别表示两个分子， $N_k(x_i)$ 是 x_i 的 k 近邻集合， $I(\cdot)$ 为指示函数，当 x_i 是 x_j 的 k 近邻或 x_j 是 x_i 的 k 近邻时取值为 1，否则为 0； $f(x_i, x_j)$ 为两原子之间的作用力（公式 4-1），作为相应近邻关系的权重。

根据分子间动能的大小，我们可以利用轮盘赌算法来选择参与合成反应的分子。但需要注意的是，合成反应并不是每次都能顺利执行。化学反应优化算法通常采用公式(2-16)来判断合成反应是否成功。然而，由于该判定标准较为宽松，仅要求新生成分子的势能不超过反应前两个分子势能与动能之和，导致许多实际上不应成功的反应被错误接受。为此，本研究借鉴了吉布斯自由能变化（ $\Delta G < 0$ ）作为反应自发性的判据，即只有在产物能量低于反应物总能量时，反应会自发进行。基于这一思想，本文提出了一种新的判定条件 RA_1 ，如下所示：

$$RA_1: PE_{new} < PE_{mol1} + PE_{mol2} \quad \text{公式(4-4)}$$

通过引入这一判定标准，能够筛选出符合热力学自发性条件的合成反应。

然而，合成反应能否顺利进行不仅取决于反应物和生成物的能量关系，而是受多种因素的综合影响。分子间的电子云分布在反应中的作用同样至关重要，当两个结构相似的分子在某些局部区域电子云重叠时，会形成具有亚稳态性质的分子间复合物，从而降低反应的能垒并促进化学键的形成，因此有必要量化分析化学键的形态。

分析化学键形态可以从中心原子入手，中心原子是指化学分子中处于核心位置的原子，它通常是连接其他原子的枢纽，共同决定了分子的结构和化学性质。因此，首先要识别出主导这一反应的中心原子对，然后通过分析中心原子对之间的电子云重叠程度预测反应的可行性。

在理论研究与实验分析中，中心原子的识别通常基于与邻近原子间的相互作用强度。在分子 M 中，每个原子 a 都被赋予一个评价函数 E ，用于量化其与周围原子的相互作用强度：

$$E(a) = \sum_{b \in N_k(a)} f(a, b) \quad \text{公式(4-5)}$$

其中， $N_k(a)$ 表示原子 a 的 k 近邻， $f(a, b)$ 为两原子之间的作用力（公式 4-1）。

需要注意的是，分子中可能存在多个中心原子，且在不同反应起主导作用的中心原子可能各不相同。因此，为确定主导反应的中心原子，我们寻找靠近另一个分子且与其自身邻近原子具有较强相互作用的原子作为此次合成反应起作用的中心原子。本文采用广度优先搜索（BFS）策略来实现这一思想：首先令起始层为 L_1 ，包含跨分子作用最强的原子；对于 $k \geq 2$ ，定义第 k 层候选原子集合为：

$$L_k = \bigcup_{a \in L_{k-1}} \{b \in M \text{ and } b \in N_k(a) \text{ and } b \notin \bigcup_{j=1}^{k-1} L_j\} \quad \text{公式(4-6)}$$

并从中选取评价函数最大的原子：

$$a_k = \arg \max_{b \in L_k} E(b) \quad \text{公式(4-7)}$$

当满足 $E(a_k) < E(a_{k-1})$ 时，搜索终止，并将 a_{k-1} 确定为这次反应起主导作用的中心原子。




图 4-3 中心原子搜索过程示意图

如图 4-3 中各层原子的评价价值依次为 $E(a_1) = 1.98$ 、 $E(a_2) = 6.87$ 、 $E(a_3) = 8.39$ 和 $E(a_4) = 7.24$ ；因 $E(a_4) < E(a_3)$ ，最终确定 a_3 为中心原子。具体确定分子 M 的中心原子过程如算法 4-3 所示。

 算法 4-3 获取主导反应的中心原子 $pickCentralAtom(M,p)$

输入：分子 M ,起始点 p

输出：中心原子 c

- 1) $L_1 \leftarrow \{p\}, a_1 \leftarrow p, k \leftarrow 2$
 - 2) while True do
 - 3) $L_k \leftarrow$ 使用公式 4-6 得到第 k 层候选原子集合
 - 4) if $|L_k| == 0$ then
 - 5) return a_{k-1}
 - 6) $a_k \leftarrow$ 使用公式 4-7 从中选取评价函数最大的原子
 - 7) if $E(a_k) < E(a_{k-1})$ then
 - 8) return a_{k-1}
 - 9) $k \leftarrow k + 1$
 - 10) end while
 - 11) return c
-

在宏观尺度上，我们将每个原子看作是固定带有一定数量电子的点粒子。在这种情况下，一个区域内原子数目越多，该区域内电子的总数也会越多，从而可以认为电子密度与原子密度成正比。在确定中心原子 c_1 和 c_2 后，算法分别以这两

个原子为中心构建局部区域作为电子云分布区域，将其称作临界区。我们首先计算各自临界区的原子密度分布，紧接着再计算两分子间过渡区的原子密度分布，如算法 4-4 所示：

算法 4-4 基于临界区和过渡区原子密度分布分析算法 $Dens(M_1, M_2)$

输入：分子 M_1 和 M_2

输出： N_{center} 、 N_1 、 N_2

- 1) $p_1, p_2 \leftarrow \underset{x_1 \in M_1, x_2 \in M_2}{\operatorname{argmax}} f(x_1, x_2)$ // 即两分子中距离最近的那对原子
 - 2) $c_1 \leftarrow \operatorname{pickCentralAtom}(M_1, p_1)$ // 算法 4-3
 - 3) $c_2 \leftarrow \operatorname{pickCentralAtom}(M_2, p_2)$ // 算法 4-3
 - 4) $r \leftarrow \max(d(c_1, p_1), d(c_2, p_2))$
 - 5) $S_{b1} \leftarrow \{x \mid x \in M_1 \text{ and } d(c_1, x) \leq r\}$
 - 6) $S_{b2} \leftarrow \{x \mid x \in M_2 \text{ and } d(c_2, x) \leq r\}$
 - 7) $S \leftarrow \{x \mid x \in M_1 \cup M_2 \text{ and } d\left(\frac{p_1 + p_2}{2}, x\right) \leq r\}$
 - 8) $N_t \leftarrow |S|$ 、 $N_{b1} \leftarrow |S_{b1}|$ 、 $N_{b2} \leftarrow |S_{b2}|$
 - 9) return N_t 、 N_{b1} 、 N_{b2}
-

其中 $d(a, b)$ 是 a, b 两点之间的欧氏距离。

在得到过渡区与临界区的密度分布后，可能有两种情况：过渡区的密度较低，与两个临界区的密度都有一定的差距，这时候两分子之间几乎没有什么电子云重叠，因此反应几乎不会进行，如图 4-4(a)所示。如果过渡区的密度较高，接近临界区密度，说明两个分子的电子云有一定的重叠，反应有较大概率会进行，如图 4-4(b)所示。





图 4-4 临界区和过渡区密度示意图

因此我们为合成反应给出潜在化学键的两个形态约束 RB_1 和 RB_2 。即当临界区的密度分布和过渡区的密度满足以下条件时,表明两个临界区结构相似的分子存在电子云重叠,为形成稳定的化学键提供了依据:

$$RB_1: N_t \geq 0.8 \cdot \min(N_{b1}, N_{b2}), \quad \text{公式(4-8)}$$

$$RB_2: \frac{\max(N_{b1}, N_{b2})}{\min(N_{b1}, N_{b2})} \leq 1.5 \quad \text{公式(4-9)}$$

如图 4-5 所示,合成后新分子的势能为 PE_{new} 较高,并不满足 RA_1 约束,但是这两个分子存在一定的电子云重叠,所以该反应仍有可能进行下去。


 图 4-5 RB_1, RB_2 约束必要性示意图

Ros 等人^[61]提出 Munec 算法通过类似临界区的局部邻域分析,结合动态同

质性指数（用于衡量簇间结构相似性的指标）的阈值调节机制来判断两个簇是否合并成功，在处理非凸数据集时能够识别复杂数据集取得了一定效果。本文则是在分析两簇的临界区的基础上，引入过渡区，通过临界区与过渡区的原子密度关系，以判断两簇之间的重叠程度来判断合成反应是否成功。

一种思路是能量约束和形态约束满足一项即可。也就是说判定合成反应成功的逻辑为 RA_1 or (RB_1 and RB_2)：当满足热力学自发条件 RA_1 时，即新生成的分子相较原分子没有过于明显的可切割结构，则合成反应可直接进行；当热力学条件未满足但两分子存在显著的电子云重叠 RB_1 and RB_2 时，即两个簇之间临界区域的链接的稳定度较高，也允许通过过渡态形成路径进行反应。

然而，上述简单思路与实际不符，如果两个结构相似的分子有一定的电子云重叠，即满足条件 RB_1 and RB_2 ，但反应物与产物势能差异过大而不满足 RA_1 ，反应的实际可行性会大打折扣。为此，我们提出弱热力学条件 RA_2 ，它是热力学条件 RA_1 的松弛版本。即当仅通过 RB_1 and RB_2 触发合成时，需再验证弱热力学条件 RA_2 ，避免在反应物与产物能量差异过大的情况下强行合成：

$$RA_2: PE_{mol1} + PE_{mol2} > \frac{1}{2} PE_{new} \quad \text{公式(4-10)}$$

类似地，当仅通过热力学条件 RA_1 触发合成时，需额外验证条件 RB_3 、 RB_4 ，避免几乎没有电子云重叠或者两分子结构差异太大的反应进行：

$$RB_3: N_t > \frac{2}{3} \min(N_{b1}, N_{b2}) \quad \text{公式(4-11)}$$

$$RB_4: \frac{\max(N_{b1}, N_{b2})}{\min(N_{b1}, N_{b2})} < 5 \quad \text{公式(4-12)}$$

即当且仅当以下两个条件至少满足一项时，合成反应成功：(1) RA_1 and RB_3 and RB_4 (2) RA_2 and RB_1 and RB_2 。

分子在反应中往往会经历不断地合成与分解循环。也就是说，在某些情况下，一个分子可能会经历合成、分解、再合成的反复过程。初次合成的新分子通常处于亚稳态，因此较容易发生分解。而经过分解后再重新合成的产物则可能重新组合逐渐形成更稳定的新分子构型。这些更稳定的构型通常具有更高的分解活化能，这使得它们的分解反应更难进行。在分子经历的合成分解循环次数达到一定次数时，认为其拥有足够高的分解活化能，后续无法再进行分解反应。整个合成反应过程如算法 4-5 所示：

算法 4-5 合成反应 $\text{syn}(A, \text{tol}, \text{synRecord})$

输入：分子集 $A = \{A_1, A_2, \dots, A_n\}$, 容忍次数 tol , 合成记录 synRecord

输出：更新后的分子集, 新合成记录 synRecord

- 1) for each $1 \leq i < j \leq n$ do
 - 2) $KE_{ij} \leftarrow KE(A_i, A_j)$ // 公式 4-3
 - 3) end for
 - 4) for each $1 \leq i < j \leq n$ do
 - 5) $P_{ij} \leftarrow \frac{KE_{ij}}{\sum_{1 \leq i \leq j \leq n} KE_{ij}}$
 - 6) end for
 - 7) 根据概率 P 从分子集 A 中选出分子 M_1, M_2
 - 8) $M \leftarrow M_1 \cup M_2$
 - 9) $PE_{\text{new}} \leftarrow PE(M), PE_{\text{mol}_1} \leftarrow PE(M_1), PE_{\text{mol}_2} \leftarrow PE(M_2)$ // 公式 4-2
 - 10) $N_t, N_{b1}, N_{b2} \leftarrow \text{Dens}(M_1, M_2)$ // 算法 4-4
 - 11) if $RA_1 \&\&RB_3 \&\&RB_4 \parallel RA_2 \&\&RB_1 \&\&RB_2$ then
 - 12) $\text{atomSet} \leftarrow$ 将 M 的原子集合转换为不可变集合
 - 13) $\text{synRecord}[\text{hash}(\text{atomSet})] += 1$
 - 14) if $\text{synRecord}[\text{hash}(\text{atomSet})] \geq \text{tol}$ then
 - 15) M 不再参加后续的分解反应
 - 16) $A \leftarrow (A - \{M_1\} - \{M_2\}) \cup M$
 - 17) end if
-

算法 4-5 首先计算两两分子之间的动能，根据动能使用轮盘赌算法选择出待合成的分子（步骤 1-7）。通过检查条件 $RA_1, RA_2, RB_1, RB_2, RB_3, RB_4$ 以确保合成反应符合一定热力学条件并具有一定的电子云重叠。如果反应成功，则检查分子累计合成成功的次数，达到一定次数则认为该分子拥有足够高的分解活化能，不再参加后续的分解反应，并更新分子集。（步骤 8-17）。

4.2.4 自适应化学反应聚类算法

传统聚类方法往往依赖用户预先设定簇数，但在实际应用中，确定最优簇数是具有挑战性的难题。为了解决这一问题，本文提出了一种自适应机制，通过合成与分解反应的交替进行，动态调整簇数。

具体而言，算法在连续执行 g 次合成反应后，会统计反应成功的次数；如果成功次数少于 $1/5 * g$ （即成功率低于 20%），算法执行分解反应以调整聚类结

构。自适应化学反应聚类算法（Adaptive Chemical Reaction Optimization Clustering, ACROC）的详细执行步骤见算法 4-6 所示。

算法 4-6 ACROC 算法

输入：数据集 D , 近邻数量 k , 最大迭代次数 M , 检查间隔 g , 容忍次数 tol

输出：聚类结果 $labels$

```

1) 初始化  $synRecord$ 
2)  $molSet \leftarrow init(D, k)$  // 算法 4-1
3) 当前迭代次数  $m \leftarrow 0$ , 分解反应成功标志  $flag \leftarrow True$ 
4) while  $m < M$  do
5)      $m \leftarrow m + 1$ 
6)      $molSet, synRecord \leftarrow syn(molSet, tol, synRecord)$  // 算法 4-5
7)     if  $m \% g == 0$  then
8)         if 反应成功次数少于  $1/5$  then
9)              $molSet, flag \leftarrow div(molSet)$  // 算法 4-2
10)            if not  $flag$  then
11)                分解失败，反应结束(break)
12)        end if
13)    end while
14) count  $\leftarrow 0$ 
15) 最终的聚类结果  $labels \leftarrow []$ 
16) for  $mol \in molSet$  do
17)     for  $atom \in mol$  do
18)          $labels[atom] \leftarrow count$ 
19)     end for
20)      $count \leftarrow count + 1$ 
21) end for
22) return  $labels$ 

```

算法 4-5 首先利用数据集 D 和近邻数量 k 构建近邻图，并使用算法 4-1 初始化分子集（步骤 1-2）。在迭代过程中优先执行合成反应，每隔 g 次迭代检查反应成功率，如果成功率低于 $1/5$ 说明容器中已经很难再次发生合成反应了，则进行分解反应；若分解失败，即容器中的分子都具有较高的分解活化能，均无法分解，则整个反应结束（步骤 4-12）。反应结束后，得到最终的分子集，遍历每个分子中的原子给他们设置标签作为最终的聚类结果返回（步骤 13-21）。

4.3 实验及分析

4.3.1 实验设计

本章使用 12 个非凸数据集对 ACROC 算法的聚类性能进行测试与评估。对比算法包括谱聚类 (Spectral^{*})、凝聚层次聚类 (HAC^{*})、DBSCAN、Munec^[61]、SCA^[62]、改进的 MeanShift (NNRMS)^[63]。其中 ACROC 算法的代码已开源至 <https://github.com/AnonymousC2017/The-Research-on-Clustering-Algorithm-Based-on-Chemical-Reaction-Optimization/tree/main/V1/C4/ACROC>。上标星号表示该算法需要预设簇数。表格最后一行的 win/tie/lose 分别表示在与各算法比较中, ACROC 算法更优、持平和更差的次数。

在实验中, 最大迭代次数为 300, 近邻数设为 9, 容忍次数为 5, 检查间隔为 10。对比算法的相关参数均依据各自原论文中的建议进行设置。

4.3.2 实验结果与分析

实验结果如表 4-4、表 4-5 所示。通过实验可知, ACROC 算法能够在非凸数据集上很好地进行聚类。特别是在 Jain、SmileFace 及 Spiral 数据集上, 算法能够自适应的完全匹配真实簇结构。需要特别提及凝聚型层次聚类 (HAC), ACROC 算法的合成反应步骤在思想上与凝聚型层次聚类有相似之处—都是通过逐步合并局部相似数据构建簇结构。然而, 传统的凝聚型层次聚类在处理像 Spiral 这样的数据集时表现不佳, 原因在于其简单的合并规则难以捕捉到数据的连续性和复杂几何形状, 而 ACROC 通过动态合成与分解机制成功捕捉到螺旋间的连续性特征。谱聚类在预设簇数的前提下, 基于图切割策略在部分非凸数据集上能取得较好效果, 但在 Compound、Flame 等数据集中表现较差。此外, 改进的 MeanShift、基于互近邻的 Munec 算法以及基于 KDE 密度估计的新型粒子群聚类算法 SCA 虽然都能自适应地处理非凸数据问题, 但在某些非凸数据集中, 这些算法的聚类性能仍存在不足。最后, 展示了部分算法在非凸数据集上聚类效果图, 如图 4-6~图 4-17 所示。

表 4-4 算法 NMI 对比（均值）

Datasets	Spectral*	HAC*	DBSCAN	NNRMS	Munec	SCA	ACROC
Aggregation	0.9851	0.9822	0.9718	0.9915	0.8318	0.9503	0.9884
Compound	0.7674	0.7803	0.9511	0.9040	0.7684	0.7668	0.9849
Flame	0.0242	0.5907	0.8998	0.9269	0.0242	1	0.9634
Jain	1	0.3913	0.8616	0.4952	0.5371	0.5243	1
SmileFace	0.5793	0.7981	0.9964	0.8640	0.8260	0.9843	1
Spiral	1	0.0076	1	0.7212	1	0.5344	1
R15	0.9942	0.9864	0.9459	0.9942	0.9071	0.9942	0.9872
Zelnik2	0.5036	0.5165	1	0.5542	0.8939	0.5173	0.9831
Zelnik4	0.7200	0.7224	1	0.7201	0.8435	0.7216	0.9794
Diamond9	0.9979	0.9961	0.9644	1	0.9143	0.9979	0.9927
Complex9	0.8912	0.7068	0.7723	0.8174	0.7218	0.8174	0.9688
Elliptical_10_2	0.9857	0.9957	0.9201	0.9777	0.9539	0.9760	0.9738
win/tie/lose	7-2-3	10-0-2	9-1-2	8-0-4	11-1-0	8-0-4	-

表 4-5 算法 ARI 对比（均值）

Datasets	Spectral*	HAC*	DBSCAN	NNRMS	Munec	SCA	ACROC
Aggregation	0.9898	0.9891	0.9799	0.9949	0.7297	0.8933	0.9920
Compound	0.5311	0.5829	0.9755	0.8506	0.7240	0.5345	0.9945
Flame	0.0128	0.4167	0.9550	0.9666	0.0128	1	0.9832
Jain	1	0.3243	0.9411	0.2446	0.3306	0.5896	1
SmileFace	0.4899	0.7308	0.9975	0.7446	0.7809	0.9909	1
Spiral	1	0.0018	1	0.7464	1	0.3079	1
R15	0.9928	0.9820	0.9357	0.9928	0.8552	0.9928	0.9821
Zelnik2	0.4210	0.4203	1	0.5360	0.8836	0.4215	0.9901
Zelnik4	0.6497	0.6492	1	0.6499	0.7989	0.6482	0.9842
Diamond9	0.9985	0.9963	0.9682	1	0.8547	0.9985	0.9940
Complex9	0.8437	0.4222	0.5136	0.6258	0.3499	0.6258	0.9314
Elliptical_10_2	0.9785	0.9955	0.8133	0.9661	0.8831	0.9559	0.9661
win/tie/lose	7-2-3	10-0-2	9-1-2	8-1-3	11-1-0	9-0-3	-




图 4-6 三种算法在 Aggregation 数据集聚类结果




图 4-7 三种算法在 Compound 数据集聚类结果




图 4-8 三种算法在 Flame 数据集聚类结果




图 4-9 三种算法在 Jain 数据集聚类结果




图 4-10 三种算法在 SmileFace 数据集聚类结果




图 4-11 三种算法在 Spiral 数据集聚类结果




图 4-12 三种算法在 R15 数据集聚类结果




图 4-13 三种算法在 Zelnik2 数据集聚类结果




图 4-14 三种算法在 Zelnik4 数据集聚类结果




图 4-15 三种算法在 Diamond9 数据集聚类结果




图 4-16 三种算法在 Complex9 数据集聚类结果




图 4-17 三种算法在数据集 Elliptical_10_2 聚类结果

ACROC 算法的聚类性能高度依赖于近邻数 k 的设置。为此，接下来将在

SmileFace、R15、Compound、Zelnik4 这四个数据集上，分别将 k 设置为 {6,7,8,9,10,11,12}，对比分析不同 k 值对聚类效果的影响。实验结果如图 4-18 所示。




图 4-18 近邻数 k 对聚类效果的影响

从图中可以看出， k 取值为 9 时效果最好，因此实验中时 ACROC 参数 k 的取值设置为 9。

此外，算法还涉及参数最大迭代次数 M ，为了研究 M 对聚类效果的影响，我们在 SmileFace、R15、Compound、Zelnik4 这四个数据集上，将 M 设置为 {50,100,150,200,250,300,350}，对比分析不同 M 值对聚类效果的影响。实验结果如图 4-19 所示。




图 4-19 最大迭代次数 M 对聚类效果的影响

从图中可以看出，最大迭代次数 M 会影响算法的性能， M 应该取一个较大值，确保反应可以充分进行。因此考虑实验中将 ACROC 参数 M 的取值设置为 300。

4.4 本章小结

本章提出了一种自适应化学反应优化聚类算法，以应对传统聚类方法在处理非凸数据结构及自动确定簇数方面的局限性。该算法将聚类类比为化学反应过程，首先基于互近邻关系构建初始分子集；接着，引入谱分解理论评估分子的势能，通过 KMeans 对指示向量进行调整以有效切割分子中的弱连接部分。接着，使用跨分子间作用力量化分子动能以评估分子间的反应倾向，结合热力学自发性原理和中心原子间的电子云重叠程度，构建了更为严格的反应可行性判据体系；在优化过程中，根据合成反应的成功率触发分解反应，从而自适应地调整簇数与结构。实验结果表明，该算法在处理非凸数据集时表现优异。

结论

化学反应优化算法因其结构简单、计算高效，在优化问题中表现出色，尤其在聚类中能有效调整簇中心以实现聚类。然而，该算法收敛精度低且易陷入局部最优，因此实际的效果不佳。此外，基于簇中心优化的聚类方法在处理复杂数据集时能力有限，往往需要预先指定簇数。针对以上这些问题，本研究提出了一系列改进方案，具体内容及成果如下：

(1) 由于实数编码化学反应优化算法收敛精度低且易陷入局部最优，本文提出改进的 IRCCRO 算法，对 RCCRO 从三方面进行改进：通过引入 Sine 混沌映射优化分子集初始化，有效提高了初始解的多样性，为算法提供更全面的搜索起点；设计了基于自适应算术交叉的双分子无效碰撞反应，实现了信息的有效融合，与单分子撞墙搜索形成明显区分；将改进后的黄金正弦算法作为合成算子，有效弥补单一算法的不足，提升算法整体的性能。在 12 个基准测试函数上的实验结果表明，本文提出的 IRCCRO 比基本 RCCRO 及其改进变体具有更强的寻优能力。最后将 IRCCRO 直接优化簇中心以实现聚类，在 15 个 UCI 数据集上的实验结果表明，本文提出的 IRCCROC 相比 6 种经典或者先进的聚类算法有更好的性能。

(2) 针对传统聚类算法在非凸数据集上表现不佳且需预先指定簇数的局限，本文创新性地提出了一种基于化学反应机制的自适应聚类算法。该算法基于互邻近关系构建初始分子集，并通过合成反应与分解反应的动态交替执行实现簇结构的自适应优化。在分解阶段，引入谱分解理论计算分子势能并进行分解；在合成阶段，结合吉布斯自由能判据和中心原子间的电子云重叠程度评估合成可行性。在 12 个非凸数据集上的实验结果表明，该算法在处理复杂形状数据集时相较于 6 种经典或者先进的聚类算法有更好的性能。

虽然本文对化学反应优化算法在聚类问题上的研究取得了一定进展，但是仍然存在一些方面需要改进和提升，以后的工作可以从以下几个方面开展：

(1) 本文提出的改进实数编码化学反应优化算法主要通过大量测试函数的数值实验验证了其优化性能，但在理论分析方面仍显不足。未来的工作中，有必要引入严格的数学理论对算法的收敛性、稳定性及全局搜索能力进行深入剖析，以期能为算法提供更为坚实的理论支撑。

(2) 本文提出利用实数编码化学反应优化算法直接优化簇中心，需要预先指定簇的个数。然而，理论上通过设计合适的适应度函数，可以实现自动聚类。未来的工作将致力于探索和构造更为合理的适应度函数。

(3) 本文提出的自适应化学反应聚类算法在处理非凸数据集时表现出较好

的性能，但在真实数据集上的应用效果仍有提升空间。这可能是因为随着维度的增加，数据的稀疏性也增加，导致设计的合成反应判定式失效。所以未来研究将致力于改进合成反应判定机制。

(4) 本文提出的化学反应优化聚类算法收敛速度较慢，未来研究将设计简化版或近似优化策略，在保持聚类效果的前提下进一步减少计算开销，提高算法实用性。

参考文献

- [1] Benjelloun S, Aissi M E M E, Loukili Y, et al. Big Data Processing: Batch-based processing and stream-based processing[C]//2020 Fourth International Conference On Intelligent Computing in Data Sciences (ICDS). 2020: 1-6.
- [2] Ezugwu A E, Ikotun A M, Oyelade O O, et al. A comprehensive survey of clustering algorithms: State-of-the-art machine learning applications, taxonomy, challenges, and future research prospects[J]. Engineering Applications of Artificial Intelligence, 2022, 110: 104743.
- [3] Saxena A, Prasad M, Gupta A, et al. A review of clustering techniques and developments[J]. Neurocomputing, 2017, 267: 664-681.
- [4] Chen W, Liu X, Zhang S, et al. Artificial intelligence for drug discovery: Resources, methods, and applications[J]. Molecular Therapy - Nucleic Acids, 2023, 31: 691-702.
- [5] Gao M, Ma Z, Rezova N L, et al. Approach to text data clustering based on molecular chemical reactions in agricultural and food industries[J]. IOP Conference Series: Earth and Environmental Science, 2022, 1112(1): 012056.
- [6] Adam S P, Alexandropoulos S A N, Pardalos P M, et al. No Free Lunch Theorem: A Review[J]. Approximation and optimization: Algorithms, complexity and applications, 2019: 57-82.
- [7] Ikotun A M, Ezugwu A E, Abualigah L, et al. K-means clustering algorithms: A comprehensive review, variants analysis, and advances in the era of big data[J]. Information Sciences, 2023, 622: 178-210.
- [8] Bhardwaj A, Pandey A, Dahiya S. Review based on Variations of DBSCAN algorithms[C]//2022 6th International Conference on Intelligent Computing and Control Systems (ICICCS). 2022: 733-739.
- [9] Agarwal S, Kumar S. Survey on Clustering Problems Using Metaheuristic Algorithms[C]//2024 11th International Conference on Reliability, Infocom Technologies and Optimization (Trends and Future Directions) (ICRITO). 2024: 1-5.
- [10] Ezugwu A E. Nature-inspired metaheuristic techniques for automatic clustering: a survey and performance study[J]. SN Applied Sciences, 2020, 2(2): 273.
- [11] Figueiredo E, Macedo M, Siqueira H V, et al. Swarm intelligence for clustering — A systematic review with new perspectives on data mining[J]. Engineering Applications of Artificial Intelligence, 2019, 82: 313-329.
- [12] Yang X S. Nature-inspired optimization algorithms: Challenges and open problems[J]. Journal of Computational Science, 2020, 46: 101104.
- [13] Kumar A, Nadeem M, Banka H. Nature inspired optimization algorithms: a comprehensive overview[J]. Evolving Systems, 2023, 14(1): 141-156.

- [14] Rahman M A, Islam M Z. A hybrid clustering technique combining a novel genetic algorithm with K-Means[J]. Knowledge-Based Systems, 2014, 71: 345-365.
- [15] Niu B, Duan Q, Tan L, et al. A Population-Based Clustering Technique Using Particle Swarm Optimization and K-Means[C]//Advances in Swarm and Computational Intelligence. Cham: Springer International Publishing, 2015: 145-152.
- [16] Pacheco T M, Gonçalves L B, Ströele V, et al. An Ant Colony Optimization for Automatic Data Clustering Problem[C]//2018 IEEE Congress on Evolutionary Computation (CEC). 2018: 1-8.
- [17] Güngör Z, Ünler A. K-harmonic means data clustering with simulated annealing heuristic[J]. Applied Mathematics and Computation, 2007, 184(2): 199-209.
- [18] Lam A Y S, Li V O K. Chemical-Reaction-Inspired Metaheuristic for Optimization[J]. IEEE Transactions on Evolutionary Computation, 2010, 14(3): 381-399.
- [19] Lam A Y S, Li V O K, Yu J J Q. Real-Coded Chemical Reaction Optimization[J]. IEEE Transactions on Evolutionary Computation, 2012, 16(3): 339-353.
- [20] Yu J J Q, Lam A Y S, Li V O K. Real-coded chemical reaction optimization with different perturbation functions[C]//2012 IEEE Congress on Evolutionary Computation. 2012: 1-8.
- [21] Yu J J Q, Lam A Y S, Li V O K. Adaptive chemical reaction optimization for global numerical optimization[C]//2015 IEEE Congress on Evolutionary Computation (CEC). Sendai, Japan: IEEE, 2015: 3192-3199.
- [22] Li Z, Li Z, Nguyen T T, et al. Orthogonal chemical reaction optimization algorithm for global numerical optimization problems[J]. Expert Systems with Applications, 2015, 42(6): 3242-3252.
- [23] Nguyen T T, Li Z, Zhang S, et al. A hybrid algorithm based on particle swarm and chemical reaction optimization[J]. Expert Systems with Applications, 2014, 41(5): 2134-2143.
- [24] Duc L A, Li K, Nguyen T T, et al. A new effective operator for the hybrid algorithm for solving global optimisation problems[J]. International Journal of Systems Science, 2018, 49(5): 1088-1102.
- [25] Roy P K, Bhui S, Paul C. Solution of economic load dispatch using hybrid chemical reaction optimization approach[J]. Applied Soft Computing, 2014, 24: 109-125.
- [26] Li Z, Yuan T, Yang B, et al. EBCRO: Hybrid chemical reaction with employed bee operator[C]//2017 13th International Conference on Natural Computation, Fuzzy Systems and Knowledge Discovery (ICNC-FSKD). 2017: 192-200.
- [27] Ma S, Wang Y, Zhang S, et al. Modified chemical reaction optimization and its application in engineering problems[J]. Mathematical Biosciences and Engineering, 2021, 18(6): 7143-7160.

- [28] Baral A, Behera H S. A novel chemical reaction-based clustering and its performance analysis[J]. *International Journal of Business Intelligence and Data Mining*, 2013, 8(2): 184-198.
- [29] Hudaib A, Khanafseh M, Surakhi O. An Improved Version of K-medoid Algorithm using CRO[J]. *Modern Applied Science*, 2018, 12(2): 116-127.
- [30] Daniel R, Rao K. MCRO-ECP: Mutation Chemical Reaction Optimization based Energy Efficient Clustering Protocol for Wireless Sensor Networks[J]. *KSII Transactions on Internet and Information Systems*, 2019, 13(7): 3494-3510.
- [31] Neamah A F, Ibrahim H K, Darwish S M, et al. Big Data Clustering Using Chemical Reaction Optimization Technique: A Computational Symmetry Paradigm for Location-Aware Decision Support in Geospatial Query Processing[J]. *Symmetry*, 2022, 14(12): 2637.
- [32] Nayak J. Hybrid chemical reaction based metaheuristic with fuzzy c-means algorithm for optimal cluster analysis[J]. *Expert Systems with Applications*, 2017(79): 282-295.
- [33] Panigrahi S, Rath B, Santosh Kumar P. A Hybrid CRO-K-Means Algorithm for Data Clustering[C]//*Computational Intelligence in Data Mining - Volume 3*. New Delhi: Springer India, 2015: 627-639.
- [34] Boni A P K, Islam B M R. Chemical Reaction Optimization for Minimum Weight Dominating Set[J]. *Applied Computational Intelligence and Soft Computing*, 2023, 2023: 9640807.
- [35] Xiao X, Li C, Jiang B, et al. Adaptive search strategy based chemical reaction optimization scheme for task scheduling in discrete multiphysical coupling applications[J]. *Applied Soft Computing*, 2022, 121: 108748.
- [36] Xu R, Wunsch D. Survey of clustering algorithms[J]. *IEEE Transactions on Neural Networks*, 2005, 16(3): 645-678.
- [37] Goyal M, Aggarwal S. A Review on K-Mode Clustering Algorithm[J]. *International Journal of Advanced Research in Computer Science*, 2017, 8(7): 725-729.
- [38] Ran X, Xi Y, Lu Y, et al. Comprehensive survey on hierarchical clustering algorithms and the recent developments[J]. *Artificial Intelligence Review*, 2023, 56(8): 8219-8264.
- [39] Wang Y, Qian J, Hassan M, et al. Density peak clustering algorithms: A review on the decade 2014–2023[J]. *Expert Systems with Applications*, 2024, 238: 121860.
- [40] Chen J, Zhu X, Liu H. A mutual neighbor-based clustering method and its medical applications[J]. *Computers in Biology and Medicine*, 2022, 150: 106184.
- [41] Du M, Ding S, Jia H. Study on density peaks clustering based on k-nearest neighbors and principal component analysis[J]. *Knowledge-Based Systems*, 2016, 99: 135-145.
- [42] 王丽. 瑞利商问题的理论与算法研究[D]. 长江大学, 2021.

- [43] Shi J, Malik J. Normalized cuts and image segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2000, 22(8): 888-905.
- [44] Suganthan P N, Hansen N, Liang J J, et al. Problem Definitions and Evaluation Criteria for the CEC 2005 Special Session on Real-Parameter Optimization[J]. KanGAL report, 2005, 2005005(2005): 2005.
- [45] Gao W feng, Liu S yang, Huang L ling. Particle swarm optimization with chaotic opposition-based population initialization and stochastic search technique[J]. Communications in Nonlinear Science and Numerical Simulation, 2012, 17(11): 4316-4327.
- [46] Tian D. Particle Swarm Optimization with Chaos-based Initialization for Numerical Optimization[J]. Intelligent Automation & Soft Computing, 2018, 24(2): 331-342.
- [47] Fu Y, Liu D, Fu S, et al. Enhanced Aquila optimizer based on tent chaotic mapping and new rules[J]. Scientific Reports, 2024, 14(1): 3013.
- [48] Feng J, Zhang J, Zhu X, et al. A novel chaos optimization algorithm[J]. Multimedia Tools and Applications, 2017, 76(16): 17405-17436.
- [49] Chen Y, Li L, Xiao J, et al. Particle swarm optimizer with crossover operation[J]. Engineering Applications of Artificial Intelligence, 2018, 70: 159-169.
- [50] Singh G, Gupta N. A Study of Crossover Operators in Genetic Algorithms[M]//Frontiers in Nature-Inspired Industrial Optimization. Singapore: Springer, 2021: 17-32.
- [51] Tanyildizi E. Golden Sine Algorithm: A Novel Math-Inspired Algorithm[J]. Advances in Electrical and Computer Engineering, 2017, 17(2): 71-78.
- [52] Bin Z, Zhichun G, Qiangqiang H. A Genetic Clustering Method Based on Variable Length String[C]//2019 2nd International Conference on Safety Produce Informatization (IICSPI). 2019: 460-464.
- [53] Singh H, Rai V, Kumar N, et al. An enhanced whale optimization algorithm for clustering[J]. Multimedia Tools and Applications, 2023, 82(3): 4599-4618.
- [54] Storn R, Price K. Differential Evolution – A Simple and Efficient Heuristic for global Optimization over Continuous Spaces[J]. Journal of Global Optimization, 1997, 11(4): 341-359.
- [55] Arthur D, Vassilvitskii S. k-means++: The Advantages of Careful Seeding[R]. Stanford, 2006.
- [56] Atabay H A, Sheikhzadeh M J, Torshizi M. A clustering algorithm based on integration of K-Means and PSO[C]//2016 1st Conference on Swarm Intelligence and Evolutionary Computation (CSIEC). 2016: 59-63.

- [57] Qaddoura R, Faris H, Aljarah I, et al. EvoCluster: An Open-Source Nature-Inspired Optimization Clustering Framework in Python[C]//Applications of Evolutionary Computation. Cham: Springer International Publishing, 2020: 20-36.
- [58] Gribel D, Vidal T. HG-means: A scalable hybrid genetic algorithm for minimum sum-of-squares clustering[J]. Pattern Recognition, 2019, 88: 569-583.
- [59] Béguin L, Vernier A, Chicireanu R, et al. Direct Measurement of the van der Waals Interaction between Two Rydberg Atoms[J]. Physical Review Letters, 2013, 110(26): 263201.
- [60] Von Luxburg U. A tutorial on spectral clustering[J]. Statistics and Computing, 2007, 17(4): 395-416.
- [61] Ros F, Guillaume S. *Munec*: a mutual neighbor-based clustering algorithm[J]. Information Sciences, 2019, 486: 148-170.
- [62] Zhu W, Luo W, Ni L, et al. Swarm Clustering Algorithm: Let the Particles Fly for a while[C]//2018 IEEE Symposium Series on Computational Intelligence (SSCI). 2018: 1242-1249.
- [63] Cariou C, Le Moan S, Chehdi K. A Novel Mean-Shift Algorithm for Data Clustering[J]. IEEE Access, 2022, 10: 14575-14585.

致 谢

行文至此，论文即将收笔。回望求学之路，百感交集。在此，谨向所有在我学术与生活旅程中给予指导、支持与陪伴的师长、同窗与亲友，致以最诚挚的谢意。

首先，衷心感谢我的导师何振峰老师。从选题确立到研究框架的搭建，再到论文的反复修改，您始终以严谨的治学态度和深厚的专业素养为我指引方向。您不仅是学术上的引路人，更是人生道路上的良师。师恩如海，铭记于心。

同时，感谢康泰榕、李钰群、林青松、黄丽媛学长学姐在学术问题上给予的耐心解答与无私帮助；感谢关承彬、黄礼校等同门在研究生期间的并肩协作与鼓励支持。

特别感谢我的父母、姐姐与姐夫。在我二十余载的求学历程中，是你们无条件的理解与包容，构筑了我最坚强的后盾。

最后，感谢我的女朋友王依婷，感谢你一路以来的陪伴、理解与守候。在我彷徨时鼓励，在我坚持时相伴，你的存在是我前行的重要力量。

至此，我在福州大学求学已有七载。从懵懂少年到独立思考的研究者，这里不仅见证了我的成长与蜕变，也承载了我无数珍贵的记忆与情感。离别在即，心中满是不舍。衷心感谢母校的培养与滋养，福大永远是我心中温暖的港湾。

个人简历

姓 名：陈锦聪
性 别：男
出生年月：1999.05
政治面貌：共青团员
籍 贯：福建泉州

学习及工作经历：

2022.09-2025.06	福州大学计算机与大数据学院	研究生
2017.09-2021.06	福州大学化工学院	本 科

在学期间的研究成果及发表的学术论文